

به نام خداوند



دانشگاه صنعتی شریف
دانشکده مهندسی عمران

پروژه کارشناسی

عنوان

شناسایی و طبقه‌بندی خودکار اشیاء BIM کتابخانه
ملی اشیاء با استفاده از هوش مصنوعی

نگارنده

سید امیرحسین حسینی

استاد راهنما

دکتر امین الوانچی

استاد مشاور

دکتر مسعود زواری

شهریور ۱۴۰۴

به نام خدا

تقدیر و تشکر

حمد و سپاس بیکران پروردگار یکتا را که توفیق به انجام رساندن این پژوهش را به اینجانب ارزانی داشت. بر خود لازم می‌دانم از زحمات و راهنمایی‌های بی‌دریغ استاد گرانقدر، جناب آقای دکتر امین الوانچی، که با سعه صدر، دانش عمیق و نگاه نافذشان همواره راهگشای مسیر پرفراز و نشیب این تحقیق بودند، صمیمانه سپاسگزاری نمایم. بدون شک، حمایت‌های ایشان نقشی بی‌بدیل در به ثمر نشستن این پژوهش داشته است. همچنین، از دکتر ارجمند، جناب آقای دکتر مسعود زواری که با مشاوره‌های ارزشمند و نکات دقیق خود، به غنای علمی این پایان‌نامه افزودند، کمال تشکر را دارم.

از تمامی اساتید بزرگوار دانشکده مهندسی عمران دانشگاه صنعتی شریف که در طول دوران تحصیل، چراغ راه علم و دانش را برایم روشن نگاه داشتند، سپاسگزارم.

در این میان، نمی‌توانم نقش بی‌بدیل خانواده عزیزم، به‌ویژه پدر و مادر فداکارم را نادیده بگیرم. حمایت‌های بی‌شائبه، صبر و تشویق‌های مداوم ایشان، همواره بزرگترین دلگرمی من در تمامی مراحل زندگی و به‌ویژه در دوران انجام این پژوهش بوده است. این دستاورد را به ایشان تقدیم می‌نمایم.

در پایان، از تمامی دوستان و عزیزان به‌خصوص خانم مائده دشتی و جناب آقای رهام هایدی که با همراهی و ایجاد فضایی پرانگیزه، مرا در این مسیر یاری نمودند، قدردانی می‌کنم.

سید امیرحسین حسینی

شهریور ۱۴۰۴

چکیده

با رشد روزافزون استفاده از مدل‌سازی اطلاعات ساخت (BIM)^۱ در پروژه‌های عمرانی و خطی، چالش طبقه‌بندی حجم بالای اشیاء ورودی به کتابخانه‌های BIM به یک گلوگاه اساسی تبدیل شده است. فرآیندهای دستی موجود، زمان‌بر، پرهزینه و مستعد خطای انسانی هستند. با این حال، پژوهش‌های اندکی برای برطرف نمودن این مشکل اساسی انجام شده است و غالب پژوهش‌های موجود نیز دارای محدودیت‌های جدی هستند. این پژوهش با هدف حل این چالش، به طراحی و پیاده‌سازی یک سیستم هوشمند و یکپارچه برای طبقه‌بندی خودکار اشیاء سه‌بعدی BIM می‌پردازد. در این راستا، یک فرآیند پیوسته صنعتی مبتنی بر پلتفرم ابری Autodesk Platform Services (APS) توسعه داده شد که وظیفه آماده‌سازی فایل‌ها، از جمله تبدیل فرمت RFA به RVT و رندرینگ خودکار نماهای دوبعدی را بر عهده دارد. برای طبقه‌بندی، از مدل پیشرفته یادگیری عمیق OVPT (Optimal Viewset Pooling Transformer) مبتنی بر معماری ترنسفورمر^۲ استفاده شد که با ساز و کار هوشمند انتخاب نمای بهینه بر اساس آنتروپی اطلاعات، دقت و کارایی بالایی را به نمایش می‌گذارد. مدل آموزش دیده بر روی دیتاست^۳ استاندارد ModelNet40 به دقت کلی ۹۷.۱۲٪ دست یافت. آزمون عملی سیستم نیز نشان داد که فرآیند پیوسته طراحی شده قادر است یک شیء BIM را از فرمت خام دریافت، پردازش و با موفقیت طبقه‌بندی نماید. این پژوهش یک راه‌حل پایدار، مقیاس‌پذیر و دقیق برای خودکارسازی فرآیند طبقه‌بندی اشیاء BIM ارائه می‌دهد که گامی مهم در جهت افزایش بهره‌وری و استانداردسازی در صنعت AEC^۴ محسوب می‌شود.

کلمات کلیدی: مدل‌سازی اطلاعات ساخت، کتابخانه ملی اشیاء، طبقه‌بندی خودکار اشیاء، یادگیری عمیق هندسی^۵، هوش مصنوعی، ترنسفورمر، مجموعه‌نماها^۶ (OVPT)، Autodesk Platform Services (APS)، فرآیند پیوسته

^۱ Building Information Modeling

^۲ Transformer

^۳ Dataset

^۴ Architecture, Engineering, and Construction

^۵ Geometric Deep Learning

^۶ Optimal Viewset Pooling Transformer

فهرست مطالب

چکیده.....	ا
فهرست مطالب.....	ب
فهرست جدول‌ها.....	ث
فهرست شکل‌ها.....	ث
فهرست قطعه‌کدها.....	ج
۱ - فصل اول: مقدمه و بیان مسئله.....	۱
۱-۱ بیان مسئله.....	۱
۱-۲ اهمیت و ضرورت تحقیق.....	۲
۱-۳ اهداف تحقیق.....	۲
۱-۴ نوآوری پژوهش و وجه تمایز آن.....	۳
۱-۵ ساختار پایان‌نامه.....	۳
۲ - فصل دوم: مرور ادبیات فنی.....	۴
۲-۱ مقدمه‌ای بر مدل‌سازی اطلاعات ساخت (BIM) و چالش طبقه‌بندی اشیاء.....	۴
۲-۲ رویکردهای یادگیری عمیق برای تشخیص اشیاء سه‌بعدی.....	۵
۲-۲-۱ رویکرد مبتنی بر Voxel.....	۵
۲-۲-۲ رویکرد مبتنی بر ابرنقاط.....	۵
۲-۲-۳ رویکرد مبتنی بر نما.....	۶
۲-۳ مقایسه تحلیلی معماری‌ها در حوزه BIM.....	۶
۲-۴ ظهور معماری‌های ترنسفورمر در تشخیص سه‌بعدی.....	۷
۲-۵ چالش‌های پیاده‌سازی عملی و راه‌حل‌های صنعتی.....	۷
۲-۶ جمع‌بندی و نتیجه‌گیری.....	۸
۳ - فصل سوم: روش انجام پروژه.....	۹
۳-۱ مقدمه.....	۹
۳-۲ مدل OVPT: معماری و مبانی فنی.....	۱۰

۱۰.....	۳-۲-۱ دلایل انتخاب مدل OVPT
۱۱.....	۳-۲-۲ معماری مدل OVPT
۱۴.....	۳-۳ دیتاست‌ها و آماده‌سازی داده
۱۴.....	۳-۳-۱ دلیل انتخاب دیتاست ModelNet40
۱۵.....	۳-۳-۲ مقایسه با دیتاست ArchShapesNet و دلیل عدم انتخاب آن برای ارزیابی اولیه
۱۶.....	۳-۳-۳ نحوه تقسیم داده‌های آموزش و آزمون
۱۷.....	۳-۴ فرآیند آموزش مدل
۱۸.....	۳-۵ طراحی و پیاده‌سازی فرآیند پیوسته طبقه‌بندی
۱۹.....	۳-۵-۱ معماری فنی سیستم
۲۰.....	۳-۵-۲ نمونه‌سازی اولیه منطق رندرینگ با نرم‌افزار Blender
۲۰.....	۳-۵-۳ پیاده‌سازی فرآیند پیوسته در محیط Autodesk Platform Services (APS)
۲۲.....	۳-۵-۴ جزئیات پیاده‌سازی سمت سرور و کلاینت
۲۹.....	۳-۵-۵ فرآیند فراخوانی و استنتاج نهایی
۳۰.....	۴ - فصل چهارم: پیاده‌سازی و نتایج
۳۰.....	۴-۱ مقدمه
۳۰.....	۴-۲ ارزیابی عملکرد کلی مدل
۳۱.....	۴-۳ تحلیل عملکرد براساس هر کلاس
۳۲.....	۴-۴ تحلیل ماتریس درهم‌ریختگی
۳۴.....	۴-۵ نتایج آزمون عملی فرآیند پیوسته
۳۸.....	۵ - فصل پنجم: بحث و نتیجه‌گیری
۳۸.....	۵-۱ تحلیل و تفسیر نتایج
۳۸.....	۵-۲ محدودیت‌های تحقیق
۳۹.....	۵-۳ پیشنهادات برای کارهای آینده
۴۰.....	۵-۴ نتیجه‌گیری نهایی
۴۱.....	مراجع

پیوست..... ۴۲

فهرست جدول‌ها

جدول ۱- گزارش ارزیابی عملکرد مدل آموزش دیده OVPT..... ۳۰

جدول ۲- نتایج عملکرد مدل OVPT آموزش دیده، بر هر کلاس..... ۴۲

فهرست شکل‌ها

شکل ۱- فرآیند کلی تحقیق..... ۹

شکل ۲- مقایسه‌ی عملکرد (OA: دقت کلی و AA: دقت متوسط) روش‌های مختلف تشخیص شیء سه بعدی مبتنی بر نما، ارزیابی شده بر روی مجموعه داده‌های (WU و همکاران، 2015A) و

MODELNET40 (WU و همکاران، 2015A)..... ۱۰

شکل ۳- نمایش برتری مدل OVPT در یک مقایسه‌ی حجم مدل و زمان اجرا نسبت به مدل کلاسیک و

قدرتمند MVCNN و رقیب به روز تر خود مدل CARNET..... ۱۱

شکل ۴- معماری مدل هوش مصنوعی OVPT..... ۱۲

شکل ۵- خروجی گرفتن ۲۰ نمای دوبعدی از زوایای مختلف شیء سه بعدی با استفاده از پیکربندی دوربین

دوازده وجهی..... ۱۳

شکل ۶- فرآیند پیوسته فنی طبقه‌بندی خود کار..... ۱۸

شکل ۷- رابط کاربری طراحی شده و دکمه‌ی START FULL WORKFLOW..... ۲۲

شکل ۸- صفحه‌ی انتخاب هر یک از فعالیت‌ها به صورت مستقل..... ۲۳

شکل ۹- پیام ساخته شدن APPBUNDLE و ACTIVITY انتخاب شده و انتخاب ACTIVITY مورد نظر از لیست

فعالیت‌های موجود..... ۲۳

شکل ۱۰- نمودار ستونی بررسی عملکرد مدل در هر کلاس..... ۳۱

شکل ۱۱- ماتریس درهم ریختگی..... ۳۳

- شکل ۱۲- بارگذاری فایل‌های RFA و تمپلیت RVT در رابط کاربری تحت وب..... ۳۴
- شکل ۱۳- کلیک کردن بر روی دکمه‌ی شروع فرآیند خودکار و آغاز به کار کردن پلتفرم APS..... ۳۵
- شکل ۱۴- پیام موفقیت‌آمیز بودن مرحله تبدیل فرمت RFA به RVT و شروع انجام مرحله رندریگ بلافاصله بعد از آن..... ۳۵
- شکل ۱۵- پیام موفقیت‌آمیز بودن مرحله رندریگ و خروجی قابل دانلود تصاویر..... ۳۶
- شکل ۱۶- خروجی گرفته شده از فرآیند پیوسته ایجاد شده جهت تشخیص شیء توسط هوش مصنوعی
- OVPT..... ۳۶
- شکل ۱۷- خروجی نهایی: انتخاب بهترین نماها با استفاده از آنتروپی اطلاعات آن‌ها، استفاده تنها ۶ نمای انتخاب شده از ۲۰ نمای خروجی فرآیند پیوسته طراحی شده و در نهایت پیش‌بینی درست شیء توسط مدل..... ۳۷

فهرست قطعه کدها

- قطعه کد ۱- منطق زنجیره‌ای اجرای فرآیندها در سمت سرور (از فایل RFACONVERSION.JS)..... ۲۵
- قطعه کد ۲- محاسبه موقعیت ۲۰ دوربین براساس رئوس یک دوازده وجهی..... ۲۵
- قطعه کد ۳- حلقه اصلی رندریگ برای تنظیم دوربین و خروجی گرفتن تصاویر..... ۲۶
- قطعه کد ۴- منطق اصلی سمت کلاینت جهت آغاز فرآیند پیوسته..... ۲۷
- قطعه کد ۵- خلاصه‌ای از منطق هماهنگ‌کننده در سرور NODE.JS..... ۲۸

۱ - فصل اول: مقدمه و بیان مسئله

۱-۱ بیان مسئله

در دهه‌های اخیر، صنعت معماری، مهندسی و ساخت‌وساز (AEC)^۷ با پذیرش الگوواره مدل‌سازی اطلاعات ساخت (BIM)، شاهد تحولی بنیادین بوده است. BIM فراتر از یک نمایش سه‌بعدی، یک مخزن داده یکپارچه و هوشمند است که به عنوان زبان مشترک برای همکاری میان تمامی ذی‌نفعان پروژه عمل می‌کند. یکی از ارکان حیاتی این اکوسیستم، وجود کتابخانه‌های اشیاء استاندارد است. در این راستا، کتابخانه ملی اشیاء (NLBO)^۸ با هدف استانداردسازی، کنترل کیفیت و افزایش بهره‌وری از طریق فراهم آوردن اشیاء BIM استاندارد، نقشی کلیدی ایفا می‌کند. این اشیاء معمولاً در فرمت‌های رایجی مانند RFA (فایل فمیلی نرم‌افزار Autodesk Revit)، RVT (فایل پروژه نرم‌افزار Autodesk Revit) و IFC^۹ ارائه می‌شوند.

هر شیء BIM از دو جزء اساسی تشکیل شده است: هندسه‌ی سه‌بعدی که نمایانگر شکل و ابعاد فیزیکی آن است، و مشخصات و ویژگی‌های غیرهندسی که داده‌هایی مانند مصالح، هزینه، تولیدکننده و استانداردهای عملکردی را در بر می‌گیرد. استانداردسازی در یک کتابخانه ملی بدین معناست که هر دوی این موارد باید به طور کامل با استانداردهای از پیش مشخص شده مطابقت داشته باشند. بنابراین، فرآیند کنترل اشیاء قبل از بارگذاری در کتابخانه، شامل بررسی دقیق انطباق همه‌ی این جنبه‌های هندسی و غیرهندسی با ضوابط تعریف شده است.

با این حال، با افزایش تصاعدی حجم اشیاء ورودی به این کتابخانه‌ها، یک گلوگاه اساسی پدیدار می‌شود: فرآیند کنترل، اعتبارسنجی و طبقه‌بندی این اشیاء عمدتاً به صورت دستی انجام می‌شود. این فرآیند نه تنها بسیار زمان‌بر، تکراری و پرهزینه است، بلکه به شدت مستعد خطای انسانی است. یک طبقه‌بندی نادرست می‌تواند به زنجیره‌ای از مشکلات از جمله ناهماهنگی در تصمیم‌گیری، خطاهای اجرایی، خسارات مالی و زمانی، و عدم تطابق با استانداردهای ملی و بین‌المللی منجر شود. بنابراین، نیاز به یک روش خودکار، دقیق و مقیاس‌پذیر برای طبقه‌بندی اشیاء BIM یک چالش حیاتی و حل‌نشده در این صنعت محسوب می‌شود.

^۷ Architecture, Engineering, and Construction

^۸ National Library of BIM Objects

^۹ Industry Foundation Classes

۱-۲ اهمیت و ضرورت تحقیق

هوش مصنوعی و به طور خاص، یادگیری عمیق، پتانسیل آن را دارد که فرآیند شناسایی و طبقه‌بندی اشیاء BIM را به طور کامل متحول کند. یک سیستم هوشمند می‌تواند با افزایش چشمگیر سرعت، دقت و مقیاس‌پذیری، گلوگاه‌های موجود را برطرف سازد. اهمیت این تحقیق در تأثیر مستقیم آن بر بهبود کارایی کتابخانه ملی اشیاء و در نتیجه، کل اکوسیستم BIM در سطح ملی نهفته است. خودکارسازی این فرآیند به معنای آزاد کردن منابع انسانی متخصص برای تمرکز بر وظایف پیچیده‌تر، کاهش هزینه‌های ناشی از خطا و افزایش کیفیت و قابلیت اطمینان مدل‌های BIM است.

۱-۳ اهداف تحقیق

- هدف اصلی:
- طراحی و پیاده‌سازی یک سیستم هوشمند و یکپارچه برای شناسایی و طبقه‌بندی خودکار اشیاء BIM که مبتنی بر وب بوده و نیازی به دسترسی مستقیم به نرم‌افزارهای گران‌قیمت مدل‌سازی نداشته باشد.
- اهداف فرعی:
- ❖ بررسی و انتخاب یک مدل بهینه هوش مصنوعی: تحلیل و انتخاب یک معماری یادگیری عمیق پیشرفته برای تشخیص دقیق اشیاء سه‌بعدی بر اساس ویژگی‌های بصری.
- ❖ آموزش و ارزیابی مدل: آموزش و صحت‌سنجی عملکرد مدل انتخاب‌شده بر روی دیتاست‌های استاندارد جهانی برای اطمینان از دقت و قابلیت تعمیم‌پذیری آن.
- ❖ توسعه یک فرآیند پیوسته صنعتی: ایجاد یک فرآیند پیوسته و خودکار^{۱۰} برای آماده‌سازی فایل‌های ورودی، شامل تبدیل فرمت‌های اختصاصی (مانند RFA به RVT) و استخراج نماهای دوبعدی استاندارد از اشیاء سه‌بعدی.
- ❖ پیاده‌سازی در محیط ابری: استقرار راه‌حل نهایی در یک محیط ابری به منظور افزایش دسترسی‌پذیری، مقیاس‌پذیری و سهولت استفاده برای کاربران نهایی.

۴-۱ نوآوری پژوهش و وجه تمایز آن

این پژوهش از چند جهت کلیدی نسبت به تحقیقات پیشین متمایز و نوآورانه است:

۱. پیاده‌سازی یک فرآیند پیوسته صنعتی و پایدار: در ادامه تلاش‌های ارزشمند برای حل چالش پردازش فایل‌های اختصاصی BIM، این پژوهش گامی فراتر از رویکردهای مبتنی بر خودکارسازی رابط کاربری (مانند راه‌حل هوشمندانه ارائه‌شده در پژوهش قدیمی (۱۴۰۲) با استفاده از Selenium) برداشته است. در این پژوهش یک فرآیند پیوسته صنعتی و یکپارچه با استفاده از پلتفرم ابری Autodesk Platform Services (APS) برای پردازش مستقیم فایل‌های BIM پیاده‌سازی کرده است. این معماری، با حذف وابستگی به رابط‌های کاربری وب که ذاتاً در معرض تغییر هستند، منجر به افزایش چشمگیر قابلیت اطمینان و مقیاس‌پذیری سیستم برای کاربردهای صنعتی می‌شود.
۲. استفاده از معماری پیشرفته ترنسفورمر: این تحقیق از مدل پیشرفته OVPT مبتنی بر معماری ترنسفورمر بهره گرفته است. این مدل با سازوکار هوشمند انتخاب نمای بهینه^{۱۱} بر اساس آنالیز^{۱۲} اطلاعات، دقت و کارایی فرآیند طبقه‌بندی را بهبود می‌بخشد. مقایسه نتایج نشان می‌دهد که مدل OVPT با پردازش تنها ۶ تصویر به میانگین دقت ۹۶.۷۴٪ بر روی دیتاست ModelNet40 دست می‌یابد، در حالی که مدل‌های قدیمی‌تر مانند MVCNN با پردازش ۱۲ تصویر به میانگین دقت ۸۹.۵۰٪ می‌رسند [۱]. این بهبود ۷.۲۴ درصدی در دقت، همزمان با کاهش ۵۰ درصدی در داده‌های ورودی، یک پیشرفت قابل توجه محسوب می‌شود. این انتخاب هوشمند نما به صورت پویا و بر اساس محتوای اطلاعاتی هر تصویر صورت می‌گیرد.
۳. کارایی محاسباتی برتر: مدل OVPT بر روی یک سیستم واحد از نظر حجم (۲۹.۷ مگابایت) تا ۳۴٪ سبک‌تر و از نظر زمان اجرا (۰.۱۰ ثانیه) تا ۱۷٪ سریع‌تر از مدل کلاسیک MVCNN است [۲]. این بهینگی، پیاده‌سازی راه‌حل در محیط‌های با منابع محدود را عملی‌تر می‌سازد.

۵-۱ ساختار پایان‌نامه

در فصل دوم، به بررسی مبانی نظری و پیشینه تحقیق در حوزه‌های BIM، یادگیری عمیق هندسی و چالش‌های پیاده‌سازی پرداخته خواهد شد. فصل سوم، روش‌شناسی دقیق تحقیق، شامل معماری مدل OVPT،

^{۱۱} Optimal Viewset Selection

^{۱۲} Entropy

دیتاست‌های مورد استفاده و جزئیات پیاده‌سازی فرآیند پیوسته صنعتی را تشریح می‌کند. در فصل چهارم، نتایج کمی و کیفی حاصل از ارزیابی مدل و آزمون عملی سیستم ارائه و تحلیل خواهد شد. در نهایت، فصل پنجم به بحث و نتیجه‌گیری، تحلیل نتایج، بیان محدودیت‌ها و ارائه پیشنهاداتی برای کارهای آینده اختصاص خواهد یافت.

۲ - فصل دوم: مرور ادبیات فنی

۲-۱ مقدمه‌ای بر مدل‌سازی اطلاعات ساخت (BIM) و چالش طبقه‌بندی اشیاء

مدل‌سازی اطلاعات ساخت (BIM) به عنوان یک چارچوب نوین، صنعت معماری، مهندسی و ساخت‌وساز (AEC¹³) را متحول کرده است. BIM صرفاً یک مدل سه‌بعدی نیست، بلکه یک مخزن داده غنی و یکپارچه است که به عنوان ابزار اصلی ارتباط و همکاری میان تمامی ذی‌نفعان پروژه عمل می‌کند. با این حال، یکی از بزرگترین موانع در مسیر تحقق کامل پتانسیل BIM، چالش هم‌کنش‌پذیری¹⁴ یا تبادل یکپارچه اطلاعات بین نرم‌افزارهای مختلف است.

استاندارد Industry Foundation Classes (IFC) به عنوان یک فرمت داده‌باز و خنثی، با هدف حل این مشکل توسعه یافته است. اما پیچیدگی و گستردگی طرح‌واره IFC¹⁵ باعث شده است که در عمل، تبادل داده‌ها همچنان با مشکلاتی نظیر از دست رفتن اطلاعات یا طبقه‌بندی نادرست اشیاء مواجه باشد [۳، ۴]. این خطاها در نگاشت¹⁶ بین اشیاء بومی نرم‌افزارها و موجودیت‌های متناظر آن‌ها در IFC می‌تواند ناشی از خطاهای انسانی، محدودیت نرم‌افزاری، یا عدم آگاهی کامل از ساختار پیچیده IFC باشد. این طبقه‌بندی‌های نادرست که فرآیندی به نام غنی‌سازی معنایی¹⁷ برای اصلاح آن‌ها به وجود آمده [۵، ۶]، می‌تواند منجر به خطاهای جدی در تحلیل انرژی، برآورد هزینه و بررسی انطباق با استانداردها شود.

علاوه بر این آموزش مدل‌های هوش مصنوعی نیازمند دیتاست‌های بزرگ، با کیفیت و متعادل است. اما جمع‌آوری چنین دیتاست‌هایی که در حوزه BIM به دلیل محدودیت منابع و تنوع بالای اشیاء، خود یک چالش بزرگ محسوب می‌شود. پژوهش‌ها نشان داده‌اند که عدم تعادل در تعداد نمونه‌های هر کلاس در

¹³ Architecture, Engineering, and Construction

¹⁴ Interoperability

¹⁵ Scheme

¹⁶ Mapping

¹⁷ Semantic Enrichment

دیتاست، منجر به سوگیری^{۱۸} در مدل‌های یادگیری عمیق و کاهش دقت آن‌ها می‌شود. این مسائل، ضرورت توسعه روش‌های خودکار و هوشمند برای طبقه‌بندی دقیق اشیاء BIM و همچنین ایجاد دیتاست‌های غنی و متعادل را برجسته می‌سازد.

۲-۲ رویکردهای یادگیری عمیق برای تشخیص اشیاء سه‌بعدی

پردازش داده‌های سه‌بعدی به دلیل ماهیت غیر اقلیدسی^{۱۹} آن‌ها، با چالش‌های منحصر به فردی روبروست. برخلاف تصاویر دوبعدی که ساختار شبکه‌ای منظمی دارند، داده‌های سه‌بعدی فاقد پارامترسازی سراسری و ناوردا به جابجایی^{۲۰} هستند. این حوزه که با عنوان یادگیری عمیق هندسی شناخته می‌شود، روش‌های مختلفی را بر اساس نحوه نمایش داده ورودی توسعه داده است [۷].

۲-۲-۱ رویکرد مبتنی بر Voxel^{۲۱}:

این روش فضای سه‌بعدی را به شبکه‌ای از واحدهای حجمی به نام Voxel تقسیم می‌کند. مدل‌هایی مانند 3DShapeNets[۸] و VoxNet از شبکه‌های عصبی پیچشی^{۲۲} سه‌بعدی برای پردازش این ساختار منظم بهره می‌برند. با این حال، این روش‌ها به دلیل رشد مکعبی هزینه محاسباتی و حافظه با افزایش رزولوشن، و همچنین از دست دادن جزئیات دقیق سطح، با محدودیت مواجه هستند.

۲-۲-۲ رویکرد مبتنی بر ابرنقاط^{۲۳}:

این رویکرد مستقیماً با ابرنقاط (مجموعه‌ای از نقاط نامنظم در فضا) کار می‌کند. مدل پیشگام در این حوزه، PointNet، با طراحی یک معماری هوشمندانه توانست با ویژگی نامنظم بودن نقاط در ابر نقاط مقابله کند. این شبکه با استفاده از توابع متقارن (مانند Max Pooling) و شبکه‌های تبدیل فضایی، ویژگی‌های سراسری را از کل مجموعه نقاط استخراج می‌کند [۹]. اگرچه این روش‌ها اطلاعات دقیق هندسی را حفظ می‌کنند، اما در استخراج ویژگی‌های ساختارهای محلی پیچیده با محدودیت‌هایی روبرو هستند.

¹⁸ Bias

¹⁹ Non-Euclidean

²⁰ Shift-invariance

²¹ Voxel Based

²² Convolutional Neural Networks

²³ Cloud-Point Based

۲-۲-۳ رویکرد مبتنی بر نما^{۲۴}:

این رویکرد، مسئله تشخیص سه‌بعدی را به مجموعه‌ای از تشخیص‌های دوبعدی تبدیل می‌کند. در این روش، چندین تصویر دوبعدی از زوایای مختلف یک شیء سه‌بعدی رندر شده و سپس این تصاویر به یک شبکه عصبی کانولوشنی (CNN) داده می‌شوند. مدل MVCNN^{۲۵} به عنوان مدل پایه و تأثیرگذار در این حوزه، نشان داد که این روش با بهره‌گیری از قدرت مدل‌های CNN که بر روی دیتاست‌های عظیم تصاویر از پیش آموزش دیده‌اند، می‌تواند به نتایج بسیار دقیقی دست یابد [۱۰]. این رویکرد به دلیل عملکرد پیشرفته، به یکی از موفق‌ترین روش‌ها برای طبقه‌بندی اشیاء سه‌بعدی تبدیل شده است.

۲-۳ مقایسه تحلیلی معماری‌ها در حوزه BIM

برای انتخاب بهترین رویکرد برای طبقه‌بندی اشیاء BIM، مقایسه مستقیم عملکرد معماری‌های مختلف در این حوزه ضروری است. پژوهش انجام شده توسط Koo و همکاران (2021a) [۱۱] به طور خاص به مقایسه دو رویکرد اصلی، یعنی MVCNN (مبتنی بر نما) و PointNet (مبتنی بر ابر نقاط)، برای طبقه‌بندی ۱۰ نوع از اشیاء زیرساختی BIM پرداخت. نتایج این تحقیق به طور قاطع برتری رویکرد مبتنی بر نما را نشان داد: مدل MVCNN با کسب دقت ۹۸٪، عملکردی بسیار بهتر از PointNet با دقت ۸۳٪ داشت.

تحلیل نتایج نشان داد که PointNet به دلیل اتکا به مجموعه‌ای پراکنده از نقاط (اسکلت شیء)، در تشخیص تفاوت‌های ظریف هندسی بین زیرگروه‌های مشابه (مانند انواع مختلف کالورت‌ها) با مشکل مواجه است. در مقابل، MVCNN با استفاده از ۱۲ تصویر کامل از زوایای مختلف، توانست جزئیات دقیق‌تری را ثبت کرده و اشیاء را با دقت بالاتری تفکیک کند.

با این حال، این مقاله یک شکاف پژوهشی مهم را نیز شناسایی کرد: هر دو مدل در تشخیص اشیاء بر اساس ویژگی‌های سراسری مانند اندازه یا حجم نسبی ناتوان بودند. برای مثال، MVCNN در تشخیص یک دیوار حائل از یک حوضچه که شکل مشابه اما ابعاد بسیار متفاوتی دارند، دچار خطا شد. این محدودیت نشان می‌دهد که مدل‌های مبتنی بر CNN، با وجود قدرت بالای استخراج ویژگی‌های محلی از هر نما، در تجمیع و درک روابط متقابل بین نماهای مختلف برای ساخت یک توصیفگر سراسری غنی، با چالش مواجه هستند.

^{۲۴} View Based

^{۲۵} Multi-view Convolutional Neural Network

۴-۲ ظهور معماری‌های ترنسفورمر در تشخیص سه‌بعدی

برای پاسخ به محدودیت‌های مدل‌های مبتنی بر CNN، نسل جدیدی از معماری‌ها بر پایه ترنسفورمر^{۲۶} ظهور پیدا کردند. ترنسفورمرها از ساز و کاری به نام توجه^{۲۷} برای مدل‌سازی روابط بین تمام اجزای ورودی به صورت همزمان بهره می‌برند. این قابلیت، آن‌ها را برای تشخیص چندنما ایده‌آل می‌سازد، زیرا می‌توانند به صورت کارآمد روابط و ویژگی‌های مکمل بین نماهای مختلف یک شیء را ثبت کرده و از این طریق یک درک سراسری و جامع از شکل سه‌بعدی به دست آورند.

مقالات مروری جدید مانند Alzahrani و همکاران (۲۰۲۴)^[۱] به تفصیل به این گذار از مدل‌های مبتنی بر CNN به مدل‌های مبتنی بر ترنسفورمر پرداخته‌اند و نشان می‌دهند که مدل‌هایی مانند MVT^{۲۸} و ViewFormer توانسته‌اند با استفاده از این معماری جدید، نتایج پیشرفته‌ای^{۲۹} را به ثبت برسانند [۱، ۱۲].

این پژوهش، با تکیه بر این پیشرفت‌ها، مدل OVPT^{۳۰} را به عنوان معماری منتخب خود برگزیده است [۲]. این مدل نه تنها از قدرت ترنسفورمر برای تجمیع ویژگی‌ها بهره می‌برد، بلکه با معرفی یک ساز و کار هوشمند برای انتخاب مجموعه نمای بهینه بر اساس آنتروپی اطلاعات، مشکل افزونگی نماها و هزینه‌های محاسباتی بالا را نیز به طور همزمان حل می‌کند. این رویکرد ترکیبی، OVPT را به یک راه‌حل دقیق و در عین حال کارآمد تبدیل کرده است.

۴-۵ چالش‌های پیاده‌سازی عملی و راه‌حل‌های صنعتی

فراتر از انتخاب مدل، پیاده‌سازی یک سیستم کاربردی با چالش‌های مهندسی متعددی روبروست. یکی از بزرگترین موانع در حوزه BIM، کار با فرمت‌های فایل اختصاصی مانند RFA است که پردازش مستقیم آن‌ها نیازمند راه‌حل‌های ویژه است. در پژوهش‌های پیشین (قدیری، ۱۴۰۲)، برای غلبه بر این مشکل از یک راه‌حل خلاقانه مبتنی بر خودکارسازی رابط کاربری یک نمایشگر آنلاین با کتابخانه Selenium استفاده شده است. اگرچه این روش برای اثبات مفهوم کارآمد است، اما به دلیل وابستگی شدید به عدم تغییر رابط کاربری وب‌سایت شخص ثالث، یک راه‌حل شکننده و غیرمقیاس‌پذیر برای کاربردهای صنعتی محسوب می‌شود.

²⁶ Transformer

²⁷ Attention

²⁸ Multi-view Vision Transformer

²⁹ State-of-the-Art

³⁰ Optimal Viewset Pooling Transformer

این موضوع، یک شکاف مهم در زمینه مهندسی سیستم را آشکار می‌سازد: کمبود پژوهش‌هایی که یک فرآیند پیوسته صنعتی، قوی و مقیاس‌پذیر را با استفاده از پلتفرم‌های ابری استاندارد مانند Autodesk Platform Services (APS) ارائه کرده باشند. این پلتفرم‌ها با فراهم آوردن API های قدرتمند برای پردازش مستقیم فایل‌های مهندسی در محیط ابری، راه را برای ایجاد راه‌حل‌های واقعی، قابل اعتماد و تجاری هموار می‌سازند.

۲-۶ جمع‌بندی و نتیجه‌گیری

مرور ادبیات فنی نشان داد که دو شکاف پژوهشی اصلی در زمینه طبقه‌بندی خودکار اشیاء BIM وجود دارد:


۱. شکاف در مدل‌سازی: مدل‌های کلاسیک مبتنی بر CNN مانند MVCNN، با وجود دقت بالا، در کرک روابط سراسری بین نماها و ویژگی‌های مفهومی مانند ابعاد نسبی، محدودیت دارند. این امر نیاز به معماری‌های پیشرفته‌تری مانند ترنسفورمرها را برای ایجاد توصیفگرهای غنی‌تر توجیه می‌کند.
۲. شکاف در پیاده‌سازی: راه‌حل‌های موجود برای پردازش فایل‌های اختصاصی BIM، عمدتاً آزمایشگاهی و غیرقابل اعتماد برای کاربردهای صنعتی هستند. نیاز به یک فرآیند پیوسته مهندسی، مقیاس‌پذیر و یکپارچه بر پایه پلتفرم‌های ابری صنعتی به شدت احساس می‌شود.

این پژوهش با هدف پاسخ به هر دو شکاف طراحی شده است. این کار از طریق به کارگیری مدل پیشرفته OVPT برای دستیابی به دقت و کارایی بالا در طبقه‌بندی، و پیاده‌سازی آن در قالب یک فرآیند پیوسته یکپارچه و صنعتی بر بستر پلتفرم Autodesk Platform Services (APS) انجام خواهد شد.

۳ - فصل سوم: روش انجام پروژه

۳-۱ مقدمه

در این فصل، مراحل و روش‌های به کار گرفته شده برای دستیابی به اهداف تحقیق به تفصیل تشریح می‌شود. فرآیند کلی این پژوهش، از مرحله مطالعه و شناسایی شکاف‌های موجود تا طراحی، پیاده‌سازی و ارزیابی نهایی سیستم، در شکل ۱ به صورت خلاصه نمایش داده شده است. در ادامه، جزئیات هر یک از این مراحل، شامل معماری و دلایل انتخاب مدل هوش مصنوعی، شرح دیتاست‌های مورد استفاده، فرآیند آموزش مدل و در نهایت، طراحی و پیاده‌سازی فرآیند پیوسته یکپارچه برای طبقه‌بندی خودکار اشیاء BIM، به تفصیل شرح داده خواهند شد.



شکل ۱-۱ فرآیند کلی تحقیق

همانطور که در شکل ۱ مشاهده می‌شود، این پژوهش یک مسیر سیستماتیک را دنبال می‌کند که با انتخاب یک معماری هوش مصنوعی پیشرفته آغاز شده و به پیاده‌سازی یک فرآیند پیوسته صنعتی و در نهایت تحلیل نتایج آن ختم می‌شود. بخش‌های بعدی این فصل به تشریح جزئیات فنی هر یک از این مراحل می‌پردازد.

۳-۲ مدل OVPT: معماری و مبانی فنی

۳-۲-۱ دلایل انتخاب مدل OVPT

۱. دقت بالا با منابع کمتر

این مدل با استفاده از تعداد نماهای کمتر (در این پروژه ۶ به جای ۱۲ یا ۲۰ نما) به دقت بسیار بالایی دست می‌یابد. نتایج نشان می‌دهد که OVPT بر روی دیتاست ModelNet40 به دقت کلی (OA³¹) ۹۷/۴۸٪ رسیده است، در صورتی که مدل MVCNN با پردازش بر روی ۱۲ تصویر دقت میانگین ۸۹/۵۰٪ را توانسته است کسب کند [۱]. این کاهش در تعداد تصویر مورد نیاز پردازش، کاهش هزینه‌ی محاسباتی را به همراه دارد که به کمک ساز و کار پویا تعریف شده در مدل هوش مصنوعی (ساز و کار انتخاب نمای بهینه مبتنی بر آنالیز) به دست می‌آید.

همانطور که در شکل ۲ مشاهده می‌شود، این مدل در بین تمامی مدل‌ها از سال ۲۰۱۵ تا ۲۰۲۳ که مبتنی بر دیدگاه هستند یکی از بالاترین دقت‌ها را با وجود تعداد نماهای کم به خود اختصاص داده است.

No.	Method Name	Year	# of Views	ModelNet40			ModelNet10		
				AA	OA	mAP	AA	OA	mAP
1	MVCNN	2015	12	89.50%	-	80.20%	-	-	-
2	Pairwise	2016	12	-	90.70%	-	-	94%	-
3	VolumetricMVCNN	2016	20	89.70%	92%	-	-	-	-
4	GIFT	2016	64	89.50%	-	81.94%	91.50%	-	91.12%
5	PANORAMA-NN	2017	6	-	90.70%	-	-	91.12%	-
6	PANORAMA-ENN	2018	1	-	95.56%	86.34%	-	96.85%	93.28%
7	MHBN	2018	6	93.10%	94.70%	-	95%	95%	-
8	GVCNN	2018	8	90.70%	93.10%	84.50%	-	-	-
9	MVCNN (GoogLeNet)	2018	12	-	92.20%	83%	-	-	-
10	SeqViews2SeqLabels	2018	12	91.10%	93.30%	89%	94.80%	94.82%	91.43%
11	RotationNet	2018	20	96.29%	97.37%	-	-	98.90%	-
12	Ma et al.	2018	12	-	91.05%	-	-	95.30%	-
13	VERAM	2018	9	92.10%	93.70%	-	95.30%	95.50%	-
14	MVCNN-new	2018	6	92.40%	95%	-	-	-	-
15	iMHL	2018	12	-	97.20%	-	-	-	-
16	MVSG-DNN	2019	12	92.30%	-	83.70%	94%	-	93.90%
17	RN	2019	12	92.30%	94.30%	86.70%	95.10%	95.30%	-
18	MLVCNN	2019	12	94.16%	92.84%	92.84%	-	-	-
19	G-CNN	2019	20	92.60%	94.67%	93.56%	-	96.78%	96.18%
20	DeepCCFV	2019	12	-	92.49%	-	-	-	-
21	3D2SeqViews	2019	12	91.50%	93.40%	-	-	-	92.12%
22	DomSetClust	2019	12	92.80%	93.80%	-	-	-	-
23	HGNN	2019	12	-	96.70%	-	-	-	-
24	DRCNN	2020	12	94.86%	96.84%	93.90%	99.30%	99.34%	96.15%
25	View-GCN	2020	20	96.50%	97.60%	-	-	-	-
26	HMVCN	2021	12	94.57%	92.80%	92.80%	95.7%	-	93.90%
27	MVTN	2021	20	92.20%	93.50%	92.90%	-	-	-
28	MVT	2021	20	-	97.50%	-	-	99.30%	-
29	OVPT	2022	6	96.74%	97.48%	-	99.21%	99.33%	-
30	MVDAN	2022	12	95.50%	96.60%	-	-	-	-
31	MVMSAN	2022	20	95.68%	96.96%	-	98.42%	98.57%	-
32	Yu and Cao	2023	20	-	97.13%	95.98%	-	99%	98.23%
33	VCGR-Net	2023	12	93.33%	95.62%	-	97.24%	97.79%	-
34	ViewFormer	2023	20	98.90%	98.80%	-	100%	99.30%	-
35	MVContrast	2023	12	90.24%	92.54%	90.30%	-	-	-
36	MORE	2023	1	-	97.16%	-	-	98.26%	-
37	MVCVT	2023	12	-	95.40%	-	-	98.68%	-

شکل ۲- مقایسه‌ی عملکرد (OA: دقت کلی و AA: دقت متوسط) روش‌های مختلف تشخیص شیء سه‌بعدی مبتنی بر نما، ارزیابی شده بر روی مجموعه داده‌های ModelNet40 (Wu و همکاران، ۲۰۱۵a) و ModelNet10 (Wu و همکاران، ۲۰۱۵a).

³¹ Overall Accuracy

۲. حل مشکل افزونگی نما

ساز و کار انتخاب نمای بهینه مبتنی بر آنتروپی یک راه حل هوشمندانه برای مشکل افزونگی نماهاست که در مدل‌های پیشین مانند MVCNN وجود داشت.

۳. معماری ترکیبی و پیشرفته

استفاده همزمان از CNN و Transformer باعث می‌شود این مدل هم از سوء گیری استقرایی^{۳۲} قوی CNN ها بهره‌مند شود و هم بتواند روابط متقابل بین نماهای مختلف را مدل سازی کند.

۴. کارایی بالا


مقایسه‌ی نشان داده شده در شکل ۳ بر روی یک دستگاه با مشخصات ثابت نشان می‌دهد که مدل OVPT از نظر حجم (۲۹/۷ مگابایت) و زمان اجرا (۰/۱۰ ثانیه) به مراتب بهینه‌تر از مدل‌های کلاسیک مانند MVCNN (۴۴/۸ مگابایت و ۰/۱۲ ثانیه) و حتی مدل‌های جدیدتر مانند CARNet (۴۵/۷ مگابایت و ۰/۲۰ ثانیه) است [۲].

Model	Model Size	Running Time	Relative Time Cost
MVCNN [21]	44.8 MB	0.12 seconds	0.6 ×
CARNet [44]	45.7 MB	0.20 seconds	1 ×
OVPT (Ours)	29.7 MB	0.10 seconds	0.5 ×

شکل ۳- نمایش برتری مدل OVPT در یک مقایسه‌ی حجم مدل و زمان اجرا نسبت به مدل کلاسیک و قدرتمند MVCNN و رقیب به‌روز تر خود مدل CARNet

۲-۲-۳ معماری مدل OVPT


معماری OVPT از سه بخش اصلی که در شکل ۴ آمده تشکیل شده است.



شکل ۴- معماری مدل هوش مصنوعی OVPT

۱. ساخت مجموعه نمای بهینه بر اساس آنتروپی اطلاعات: یکی از مشکلات اصلی روش‌های چندنمایی، افزونگی اطلاعاتی بین نماهای مختلف و هزینه محاسباتی بالای پردازش تمام آنهاست. مدل OVPT برای حل این مشکل، از یک روش هوشمند مبتنی بر آنتروپی اطلاعات^{۳۳} استفاده می‌کند. در این مرحله، ابتدا ۲۰ نمای دوبعدی از زوایای مختلف شیء سه بعدی با استفاده از پیکربندی دوربین دوازده وجهی خروجی گرفته می‌شود. سپس آنتروپی هر یک از این نماها محاسبه شده و نماها براساس میزان اطلاعاتی که در بر دارند، رتبه‌بندی می‌شوند. در نهایت، تنها مجموعه‌ای از نماها (در این پروژه ۶ نمای برتر) که بیشترین اطلاعات را دارند، به عنوان مجموعه نمای بهینه انتخاب شده و به مراحل بعدی ارسال می‌شوند. این رویکرد به طور قابل توجهی افزونگی را کاهش داده و هزینه محاسباتی را پایین می‌آورد.

³³ Information Entropy



شکل ۵- خروجی گرفتن ۲۰ نمای دوبعدی از زوایای مختلف شیء سه بعدی با استفاده از پیکربندی دوربین دوازده وجهی

۲. تولید توالی توکن ویژگی‌های محلی سطح پایین چند نما^{۳۴}: در این بخش مدل از یک معماری ترکیبی CNN-Transformer بهره می‌برد. ابتدا ویژگی‌های سطح پایین مختص (محلی) به هر تصویر در مجموعه نماهای بهینه، توسط یک شبکه عصبی کانولوشنی^{۳۵} که بر روی دیتاست ImageNet از پیش آموزش دیده است، استخراج می‌شود و سپس این ویژگی‌های به همراه یک کلاس توکن^{۳۶} و اطلاعات موقعیتی^{۳۷} به یک توالی از توکن‌ها تبدیل می‌شوند که برای ورود به معماری ترنسفورمر مناسب است. این ترکیب مزیت بالای قابلیت استخراج ویژگی در CNNها را با توانایی ترنسفورمرها در درک روابط سراسری بین نماهای مختلف تلفیق می‌کند.

۳. تولید توصیفگر سراسری با استفاده از Pooling Transformer: ابتدا توالی توکن‌های تولید شده به یک Pooling Transformer داده می‌شود. این بخش وظیفه تجمیع ویژگی‌های محلی و سراسری را بر عهده دارد. خروجی این بخش یک توصیفگر سراسری و فشرده از شیء سه بعدی است که تمام اطلاعات لازم برای طبقه‌بندی را در خود جای داده است. این ساز و کار به خصوص در شرایطی که دیتاست آموزشی کوچک است، به بهبود قابلیت تجمیع ویژگی‌ها کمک شایانی می‌کند.

^{۳۴} Multi-View Low-Level Local Feature Token Sequence Generation

^{۳۵} CNN: Convolution Neural Network

^{۳۶} Class Token

^{۳۷} Position Encoding

۳-۳ دیتاست‌ها و آماده‌سازی داده

برای آموزش و ارزیابی مدل‌های یادگیری عمیق در حوزه تشخیص اشیاء سه‌بعدی، استفاده از مجموعه داده‌های استاندارد و شناخته‌شده امری ضروری است. این دیتاست‌ها به عنوان یک معیار مشترک، امکان مقایسه دقیق عملکرد مدل‌های مختلف را با پژوهش‌های پیشین فراهم می‌کنند. در این پژوهش، از دو زیرمجموعه اصلی و پراستفاده از دیتاست ModelNet که در مقاله مرجع OVPT نیز به کار رفته‌اند، استفاده شده است:

- دیتاست ModelNet40: این دیتاست شامل ۱۲,۳۱۱ مدل سه‌بعدی CAD در ۴۰ دسته مختلف (مانند صندلی، میز، هواپیما و...) است. داده‌ها به صورت استاندارد به ۹,۸۴۳ نمونه‌ی آموزشی و ۲,۴۶۸ نمونه‌ی آزمایشی تقسیم شده‌اند [۸].

- دیتاست ModelNet10: این دیتاست زیرمجموعه‌ای از ModelNet40 می‌باشد که شامل ۴,۸۹۹ مدل در ۱۰ دسته اصلی قرار گرفته‌اند. داده‌ها در این مجموعه نیز به ۳,۹۹۱ نمونه جهت آموزش و ۹۰۸ نمونه جهت آزمایش تقسیم‌بندی شده‌اند [۸].

در بخش بعدی، دلایل استراتژیک انتخاب این دیتاست‌ها، به ویژه تمرکز بر روی ModelNet40 برای ارزیابی نهایی عملکرد مدل، به تفصیل تشریح خواهد شد.

۳-۳-۱ دلیل انتخاب دیتاست ModelNet40

انتخاب دیتاست مناسب یکی از ارکان اصلی برای ارزیابی دقیق و قابل مقایسه مدل‌های یادگیری عمیق است. اگرچه هدف نهایی این پژوهش، طبقه‌بندی اشیاء BIM است، اما برای آموزش اولیه و ارزیابی عملکرد پایه مدل OVPT، از دیتاست ModelNet40 استفاده شد. این انتخاب استراتژیک بر اساس دلایل زیر صورت گرفته است:

- استاندارد طلایی برای محک‌زنی^{۳۸}: دیتاست ModelNet40 به طور گسترده به عنوان معیار اصلی و استاندارد برای ارزیابی و مقایسه عملکرد الگوریتم‌های تشخیص اشیاء سه‌بعدی در جامعه علمی شناخته می‌شود. تقریباً تمام مقالات پیشرفته در این حوزه، از جمله مقاله اصلی معرفی‌کننده مدل OVPT و مقالات مروری جامع، از این دیتاست برای گزارش نتایج خود استفاده می‌کنند. استفاده از این دیتاست به ما اجازه می‌دهد تا عملکرد پیاده‌سازی خود را به طور مستقیم با نتایج گزارش شده

³⁸ Gold Standard for Benchmarking

برای مدل‌های پیشرفته (State-of-the-Art) مقایسه کرده و از صحت و کارایی مدل اطمینان حاصل کنیم.

- تنوع و عمومیت بالا: این دیتاست شامل ۴۰ دسته متنوع از اشیاء ساخته دست بشر است. آموزش مدل بر روی چنین مجموعه داده متنوعی، توانایی آن را در یادگیری ویژگی‌های هندسی عمومی و بنیادین محک می‌زند. مدلی که بتواند در این دیتاست به دقت بالایی دست یابد، نشان داده است که یک طبقه‌بنده سه‌بعدی قوی و قابل تعمیم^{۳۹} است و می‌توان با اطمینان بیشتری آن را برای حوزه‌های تخصصی‌تر مانند BIM به کار گرفت.
- قابلیت تکرارپذیری و صحت‌سنجی: از آنجایی که مدل OVPT در پژوهش اصلی بر روی ModelNet40 آموزش و ارزیابی شده است، استفاده از همین دیتاست برای تکرار نتایج^{۴۰} و صحت‌سنجی معماری مدل، یک گام ضروری در فرآیند تحقیق محسوب می‌شود.

۳-۳-۲ مقایسه با دیتاست ArchShapesNet و دلیل عدم انتخاب آن برای ارزیابی اولیه

ممکن است این سوال پیش آید که چرا از دیتاست ArchShapesNet که به طور خاص برای طبقه‌بندی اشیاء معماری BIM طراحی شده است، استفاده نشد. دیتاست ArchShapesNet دارای مزایای قابل توجهی است، از جمله ارتباط مستقیم با حوزه BIM و مهم‌تر از آن، متعادل بودن تعداد نمونه‌ها در هر کلاس که از طریق یک رویکرد نوآورانه (افزایش پارامتریک داده^{۴۱}) به دست آمده است [۱۳]. این تعادل، مشکل سوگیری مدل ناشی از عدم توازن داده‌ها را که در دیتاست‌های واقعی BIM رایج است را برطرف می‌کند.

با این حال، ModelNet40 برای اهداف این پژوهش در مرحله ارزیابی پایه، ارجحیت داشت زیرا:
 ۱. عدم امکان مقایسه گسترده: ArchShapesNet یک دیتاست جدید و تخصصی است و هنوز به اندازه ModelNet40 در مقالات مختلف مورد استفاده قرار نگرفته است. در نتیجه، مقایسه مستقیم عملکرد مدل ما با طیف وسیعی از مدل‌های دیگر امکان‌پذیر نبود.

³⁹ Generalizable

⁴⁰ Reproduce

⁴¹ Parametric Augmentation

۲. تمرکز بر ارزیابی مدل، نه دیتاست: هدف اصلی این پژوهش، پیاده‌سازی و ارزیابی یک مدل هوش مصنوعی پیشرفته (OVPT) و یک فرآیند پیوسته صنعتی (42 APS) است. برای اثبات قدرت خود مدل، بهتر است آن را بر روی یک چالش شناخته‌شده و استاندارد (ModelNet40) آزمایش کنیم. بنابراین، رویکرد این پژوهش، یک فرآیند دو مرحله‌ای منطقی را دنبال می‌کند: ابتدا، کارایی و دقت مدل OVPT بر روی معیار استاندارد و عمومی ModelNet40 اثبات می‌شود. سپس، مدل اثبات‌شده و فرآیند پیوسته صنعتی طراحی‌شده، آماده است تا در مراحل بعدی و کارهای آینده، برای حوزه‌های تخصصی با استفاده از دیتاست‌های متمرکزی مانند ArchShapesNet آموزش دیده و به کار گرفته شود.

۳-۳-۳ نحوه تقسیم داده‌های آموزش و آزمون

یکی از مراحل حیاتی در فرآیند توسعه و ارزیابی مدل‌های یادگیری عمیق، تقسیم مجموعه داده به دو بخش مجزا و مستقل است: مجموعه داده آموزش و مجموعه داده آزمون. اهمیت این عمل در این است که به ما امکان می‌دهد تا قابلیت تعمیم‌پذیری مدل به داده‌های جدید و دیده نشده را به صورت بی‌طرفانه بسنجیم. این کار از بروز پدیده برازش بیش از حد^{۴۳} جلوگیری می‌کند؛ پدیده‌ای که در آن، مدل به جای یادگیری الگوهای عمومی، داده‌های آموزشی را حفظ می‌کند و در نتیجه، عملکرد ضعیفی بر روی داده‌های جدید خواهد داشت. در این پژوهش، مطابق با رویه استاندارد در اکثر تحقیقات مشابه و همچنین مقالات مرجع، از نسبت تقسیم ۸۰ به ۲۰ استفاده شده است. این به آن معناست که:

- ۸۰ درصد از داده‌ها برای آموزش: این بخش از داده‌ها به مدل ارائه می‌شود تا الگوها، ویژگی‌ها و روابط موجود در آن‌ها را یاد بگیرد. برای دیتاست ModelNet40 این بخش شامل ۹,۸۴۳ نمونه مدل سه‌بعدی است.
- ۲۰ درصد از داده‌ها برای آزمون: این بخش از داده‌ها کاملاً از فرآیند آموزش دور نگه داشته می‌شود و مدل هیچ‌گاه آن‌ها را نمی‌بیند. پس از اتمام آموزش، از این مجموعه برای ارزیابی نهایی و بی‌طرفانه عملکرد واقعی مدل استفاده می‌شود. برای دیتاست ModelNet40، این بخش شامل ۲,۴۶۸ نمونه است.

⁴² Autodesk Platform Services

⁴³ Overfitting

این تقسیم‌بندی استاندارد تضمین می‌کند که نتایج عملکردی که در فصل چهارم ارائه می‌شود (مانند دقت^{۴۴}، بازیابی^{۴۵} و امتیاز F1^{۴۶})، معیاری قابل اعتماد از توانایی مدل در مواجهه با اشیاء BIM جدید در یک محیط عملیاتی واقعی است.

۴-۳ فرآیند آموزش مدل

فرآیند آموزش مدل با هدف دستیابی به بالاترین دقت و کارایی، در محیط و با پارامترهای زیر انجام شد:

- محیط آموزش:

برای تسریع فرآیند محاسباتی و بهره‌گیری از توان پردازشی بالا، از پلتفرم Google Colab به همراه یک واحد پردازش گرافیکی GPU T4 استفاده گردید که نسبت به GPU 1660Ti فرآیند آموزش مدل ۸۶/۶۷٪ برای هر اپیاک^{۴۷} سریع‌تر صورت گرفت. همچنین این انتخاب به دلیل عدم نیاز به نصب وابستگی‌های پیچیده، اشغال فضای حافظه دستگاه، مصرف اینترنت جهت دانلود کتابخانه‌های مورد نیاز و به دلیل سازگاری بالا، فرآیند آموزش را به کمک این پلتفرم تسهیل گشت.

- مراحل آموزش:

۱. شبیه‌سازی مخزن^{۴۸} کد رسمی OVPT از GitHub.

۲. دانلود دیتاست‌های ModelNet40 و ModelNet10

۳. تنظیم پارامترهای آموزش و اصلاح مسیر خوانش اطلاعات کد از پایه ویندوز به لینوکس

۴. اجرای اسکریپت^{۴۹} آموزش

- پارامترهای آموزش: پارامترهای کلیدی که براساس مقدارهای بهینه گزارش شده در مقاله OVPT

تنظیم شدند:

۱. نرخ یادگیری: ۰/۰۰۰۱

۲. بهینه‌ساز: Adam^{۵۰}

۳. تعداد دوره‌ها^{۵۱}: ۱۰ (با مشاهده بهترین عملکرد در دوره‌ی هشتم)

^{۴۴} Precision

^{۴۵} Recall

^{۴۶} F1 Score

^{۴۷} Epoch

^{۴۸} Cloning a Repository

^{۴۹} Script

^{۵۰} Optimizer


^{۵۱} Epochs

۴. اندازه دسته^{۵۲}: ۸

۵. معماری پایه CNN: برای استخراج ویژگی از نماها، از DenseNet-121 برای دیتاست ModelNet40 در این پروژه استفاده شد.

۳-۵ طراحی و پیاده‌سازی فرآیند پیوسته^{۵۳} طبقه‌بندی

یکی از نوآوری‌های اصلی این پژوهش، طراحی یک فرآیند پیوسته صنعتی و یکپارچه برای خودکارسازی کامل فرآیند از دریافت فایل RFA تا ارائه نتیجه طبقه‌بندی است. این فرآیند شامل تعامل میان سه جزء اصلی یعنی رابط کاربری تحت وب (کلاينت)، سرور هماهنگ‌کننده^{۵۴} و سرویس ابری Autodesk Platform Services می‌باشد. نمودار ۲، جریان داده و مراحل اجرایی این فرآیند پیوسته را به صورت دقیق نمایش می‌دهد.



شکل ۶- فرآیند پیوسته فنی طبقه‌بندی خودکار

⁵² Batch Size

⁵³ Pipeline

⁵⁴ Orchestrator

این فرآیند پیوسته با دریافت فایل‌ها از کاربر آغاز شده و به صورت زنجیروار، دو فعالیت مجزا را در محیط ابری APS اجرا می‌کند. ابتدا تبدیل فرمت صورت گرفته و سپس خروجی آن برای مرحله رندرینگ استفاده می‌شود. در نهایت، تصاویر حاصل برای تحلیل و طبقه‌بندی نهایی به مدل هوش مصنوعی OVPT ارسال می‌گردند. در ادامه، جزئیات پیاده‌سازی هر یک از اجزای این فرآیند، از جمله رابط کاربری و AppBundle‌های توسعه داده شده، تشریح خواهد شد.

۱-۵-۳ معماری فنی سیستم

سیستم طراحی شده بر پایه یک معماری سه لایه مدرن شامل کلاینت^{۵۵}، سرور^{۵۶} و سرویس ابری^{۵۷} بنا شده است. این معماری تضمین می‌کند که فرآیندهای سنگین و محاسباتی از کاربر نهایی دور شده و در محیطی مقیاس پذیر و قدرتمند اجرا شوند. اجزای این معماری عبارتند از:

- لایه کلاینت^{۵۸}: یک رابط کاربری تحت وب که با استفاده از HTML و جاوا اسکریپت سمت کلاینت توسعه یافته است. این لایه مسئولیت تعامل با کاربر، دریافت فایل‌های ورودی و نمایش گزارش زنده از وضعیت فرآیند را بر عهده دارد.
 - لایه سرور^{۵۹}: یک سرور مبتنی بر Node.js که به عنوان ارکستراتور^{۶۰} یا هماهنگ کننده کل فرآیند عمل می‌کند. این لایه درخواست‌ها را از کلاینت دریافت کرده، با سرویس ابری APS ارتباط برقرار می‌کند، فرآیندهای دو مرحله‌ای را مدیریت کرده و از طریق یک کانال ارتباطی زنده، گزارش‌ها را به کلاینت ارسال می‌کند.
 - لایه سرویس ابری (APS)^{۶۱}: پلتفرم Autodesk Platform Services که منطق اصلی پردازش فایل‌های BIM را در محیط ابری Revit اجرا می‌کند. Appbundle‌های توسعه داده شده با زبان C# در این لایه مستقر می‌شوند.
- این سه لایه از طریق API‌های استاندارد با یکدیگر تعامل دارند تا یک تجربه کاربری یکپارچه و روان را فراهم آورند.

⁵⁵ Client

⁵⁶ Server

⁵⁷ Cloud Service

⁵⁸ Front-end

⁵⁹ Back-end

⁶⁰ Orchestrator

⁶¹ Autodesk Platform Services

۳-۵-۲ نمونه‌سازی اولیه منطق رندرینگ با نرم‌افزار Blender

- چالش: استخراج نماهای دوبعدی استاندارد و یکسان از اشیاء سه‌بعدی با ابعاد و جهت‌گیری‌های متفاوت که به دیتاست آموزشی نزدیک و شبیه باشد، یک چالش فنی است.
- راه‌حل: جهت تسریع فرآیند تحقیق و توسعه و پیش از پیاده‌سازی نهایی در محیط ابری، یک کد با زبان پایتون در نرم‌افزار Blender توسعه داده شد و هدف از این مرحله نمونه‌سازی و اعتبارسنجی منطق مورد نیاز برای موارد زیر بود:

- ❖ جایگذاری خودکار دوربین‌ها در رئوس یک دوازده‌وجهی فرضی به دور شیء.
 - ❖ مرکز قرار دادن و مقیاس‌بندی خودکار شیء در کادر تصویر خروجی.
 - ❖ تنظیم نور و رنگ پس‌زمینه و شیء برای تولید تصاویری مشابه با دیتاست آموزشی.
- این مرحله به عنوان یک اثبات مفهوم^{۶۲} به استخراج و نهایی‌سازی الگوریتم رندرینگ کمک شایانی کرد.

۳-۵-۳ پیاده‌سازی فرآیند پیوسته در محیط Autodesk Platform Services (APS)

برای ایجاد یک راه‌حل مقیاس‌پذیر، صنعتی و مستقل از نرم‌افزار، کل فرآیند پردازش در پلتفرم ابری Autodesk Platform Services (APS) Design Automation پیاده‌سازی شد. این پلتفرم امکان اجرای کدهای شخصی‌سازی شده بر روی فایل‌های مهندسی را در محیط ابری فراهم می‌کند. این فرآیند پیوسته شامل دو فعالیت اصلی است که با زبان C# توسعه داده شده‌اند:

۱. فعالیت اول تبدیل فرمت فایل RFA به RVT: در این فعالیت، از AppBundle ای که در پژوهش پیشین در مقطع کارشناسی ارشد توسط مهندس شربی برای پلتفرم Design Automation توسعه داده شده بود، بهره گرفته شد. این افزونه، فایل‌های RFA را به عنوان ورودی دریافت کرده و آن‌ها را در یک فایل پروژه الگو (تمپلیت^{۶۳}) RVT بارگذاری و ذخیره می‌کند. استفاده از این ابزار به عنوان گام اول ضروری است، زیرا اعمال هرگونه تغییر دلخواه بر روی فایل با استفاده از این پلتفرم، تنها بر روی فایل‌های RVT امکان‌پذیر است و نمی‌توان فعالیت‌های بعدی مانند رندرینگ را مستقیماً بر روی فرمت RFA انجام داد.


^{۶۲} Proof of Concept

^{۶۳} Template

۲. فعالیت دوم رندرینگ خودکار نماها (Dodecahedron Render): برای این فعالیت نیز یک AppBundle توسعه داده شد که منطق به‌دست آمده از مرحله نمونه‌سازی با Blender را پیاده‌سازی می‌کند. این کد فایل RVT را باز کرده، شیء موردنظر را شناسایی کرده و به صورت خودکار ۲۰ نمای دوبعدی از آن براساس الگوی دوازده‌وجهی رندر و به عنوان خروجی ذخیره می‌کند.
- برای درک بهتر فرآیند پیاده‌سازی، آشنایی با معماری فنی Design Automation برای Revit ضروری است. این سرویس با اجرای یک نسخه بدون رابط کاربری^{۶۴} از موتور Revit بر روی سرورهای ابری Autodesk کار می‌کند. سه مفهوم کلیدی در این معماری عبارتند از:
- AppBundle: یک فایل فشرده (zip) است که حاوی افزونه‌ی سفارشی ما (فایل‌های dll، کامپایل شده از کد C#) و تمام وابستگی‌های مورد نیاز آن است. در واقع، این بسته، کدی است که قرار است در محیط ابری اجرا شود. برای این پژوهش، دو AppBundle مجزا برای فعالیت‌های تبدیل فرمت و رندرینگ توسعه داده شد.
 - Activity: یک تعریف ثبت‌شده بر روی سرور APS است که یک AppBundle مشخص را به یک موتور Revit خاص (در این پروژه، Autodesk.Revit+2024) پیوند می‌دهد. در تعریف Activity، پارامترهای ورودی و خروجی نیز به طور دقیق مشخص می‌شوند. برای مثال، فعالیت رندرینگ تعریف می‌کند که یک فایل ورودی RVT دریافت کرده و یک فایل خروجی zip (حاوی تصاویر) تولید خواهد کرد.
 - WorkItem: یک کار یا وظیفه اجرایی است. در واقع، یک WorkItem نمونه‌ای از یک Activity است که با فایل‌های ورودی مشخصی (مثلاً فایل RVT بارگذاری شده توسط کاربر) به اجرا در می‌آید. سرور ما وضعیت هر WorkItem را تا رسیدن به نتیجه نهایی (موفقیت یا شکست) پیگیری می‌کند.
- با این معماری، منطق اصلی پردازش مدل‌های BIM که در کدهای C# پیاده‌سازی شده، به صورت یک سرویس قابل اعتماد و مقیاس‌پذیر در محیط ابری اجرا می‌شود.

۴-۵-۳ جزئیات پیاده‌سازی سمت سرور و کلاینت

برای سهولت استفاده، یک رابط کاربری تحت وب همانطور که در شکل ۷ مشاهده می‌شود طراحی شد و با کمک این رابط کاربری به کاربر اجازه داده می‌شود تا فایل‌های ورودی را بارگذاری کرده و کل فرآیند تبدیل فرمت و رندرینگ را تنها با یک کلیک از طریق دکمه‌ی تعریف شده‌ی “Start Full Workflow” اجرا کند.




شکل ۷- رابط کاربری طراحی شده و دکمه‌ی Start Full Workflow

علاوه بر اینکه می‌توان از این رابط کاربری به صورت یک فرآیند پیوسته استفاده کرد، می‌توان هر دو فعالیت ذکر شده را به صورت جداگانه انجام داده و خروجی هر یک از آن‌ها را نیز مشاهده کرد.


خوب است اشاره شود که در صورت انتخاب دکمه‌ی Start Full Workflow به جز بارگذاری فایل‌های مورد نظر از طرف کاربر کار دیگری نیاز نیست؛ اما اگر برای کاربر مطلوب باشد که خروجی هر یک از فعالیت‌ها را به صورت جداگانه مشاهده و بررسی کند نیاز است تا مراحل زیر همانطور که در شکل‌های ۸ و ۹ آمده‌اند به ترتیب طی شوند:

۱. از قسمت بالا سمت راست دکمه‌ی Configure انتخاب شود.
۲. در صفحه‌ی باز شده فعالیت مورد نظر و موتور (موتور پیشنهادی Autodesk.Revit +2024 می‌باشد) مناسب را انتخاب شود.
۳. پس از دیدن پیام موفقیت‌آمیز ایجاد شدن Appbundle و فعالیت در سرور، فایل‌های مورد نیاز فعالیت را بارگذاری شود.

۴. از منوی Existing activities فعالیت ایجاد شده‌ی مناسب را انتخاب کرده، بر روی دکمه‌ی فعالیت مورد نظر کلیک شود و تا زمان نمایش فایل قابل دانلود صبر شود.



شکل ۸- صفحه‌ی انتخاب هر یک از فعالیت‌ها به صورت مستقل



شکل ۹- پیام ساخته شدن AppBundle و Activity انتخاب شده و انتخاب Activity موردنظر از لیست فعالیت‌های موجود برای درک بهتر چگونگی تعاملات بین رابط کاربری^{۶۵}، سرور^{۶۶} و سرویس APS با یکدیگر تعامل دارند تا یک تجربه‌ی کاربری یکپارچه و زنده را فراهم کنند نیاز است تا معماری آن را بررسی کنیم.

معماری این سیستم از الگوی کلاینت-سرور^{۶۷} پیروی می‌کند که ارتباط آن با سرویس ابری APS در شکل زیر به صورت مفهومی نمایش داده شده است.

^{۶۵} Front-end

^{۶۶} Back-end

^{۶۷} Client-Server

- کلاینت (مرورگر کاربر): رابط کاربری که با HTML و JavaScript (فایل ApsRFAConversion.js) توسعه یافته، در مرورگر کاربر اجرا می‌شود. وظیفه اصلی آن، دریافت فایل‌ها از کاربر و ارسال یک درخواست HTTP به سرور پروژه پس از کلیک بر روی دکمه "Start Full Workflow" است.

- سرور (Node.js): سرور پروژه که با Node.js (فایل RFAConversion.js) پیاده‌سازی شده، نقش ارکستراتور^{۶۸} یا هماهنگ‌کننده کل فرآیند را بر عهده دارد. این سرور درخواست را از کلاینت دریافت کرده، با سرویس APS ارتباط برقرار می‌کند، فایل‌ها را به فضای ابری منتقل کرده، و فرآیندهای دو مرحله‌ای (WorkItem های تبدیل و رندرینگ) را به ترتیب اجرا و مدیریت می‌کند.
- ارتباط لحظه‌ای با Socket.IO: برای ارائه گزارش زنده از وضعیت فرآیند به کاربر، از کتابخانه Socket.IO برای ایجاد یک کانال ارتباطی پایدار و دوطرفه بین کلاینت و سرور استفاده شده است. این فناوری به سرور اجازه می‌دهد تا پیام‌های وضعیت (مانند "فرآیند تبدیل فرمت آغاز شد..."، "رندرینگ با موفقیت انجام شد"، و "فایل خروجی آماده دانلود است") را به صورت آنی به مرورگر کاربر ارسال کند، بدون اینکه کاربر نیاز به بازخوانی صفحه داشته باشد.

این معماری تضمین می‌کند که فرآیندهای سنگین و زمان‌بر در سمت سرور و ابر انجام شوند، در حالی که کاربر یک تجربه کاربری روان و آگاهانه را در سمت کلاینت تجربه می‌کند.

در ادامه قطعه کدهایی برای درک کلی از نحوه کارکرد فرآیند به صورت زیر آورده شده:

در قطعه کد ۱ کدی به زبان JavaScript مشاهده می‌کنید که این کد، مغز متفکر سیستم می‌باشد و نشان می‌دهد که چگونه دو فرآیند مجزای APS به صورت یکپارچه و زنجیروار اجرا می‌شوند.

⁶⁸ Orchestrator

```
// دریافت فایل‌ها و تنظیمات اولیه...
// --- RFA مرحله ۱: اجرای فرآیند تبدیل فرمت ---
socketIO.to(browserConnectionId).emit('onComplete', 'Submitting RFA
Conversion job...');
let conversionWorkItem = await api.createWorkItem(conversionSpec);

// انتظار برای اتمام موفقیت‌آمیز فرآیند اول
let conversionStatus = await pollWorkItem(conversionWorkItem.id,
api, ...);
if (conversionStatus.status !== 'success') {
    throw new Error('RFA Conversion job failed.');
```

قطعه کد ۱- منطق زنجیره‌ای اجرای فرآیندها در سمت سرور (از فایل RFAConversion.js)

دو قطعه کد ۲ و ۳ قلب فنی کار فرآیند پیوسته در محیط ابری Revit هستند و پیاده‌سازی مستقیم الگوریتم رندرینگ را نشان می‌دهند.

```
private List<XYZ> GetDodecahedronVertices(double distance)
{
    var positions = new List<XYZ>();
    double phi = (1.0 + Math.Sqrt(5.0)) / 2.0;
    double invphi = 1.0 / phi;

    // ... (کد تولید رئوس بر اساس فرمول‌های هندسی) ...

    // نرمال‌سازی و اعمال فاصله برای تعیین موقعیت نهایی دوربین
    return positions.Select(p => p.Normalize() *
distance).ToList();
}
```

قطعه کد ۲- محاسبه موقعیت ۲۰ دوربین براساس رئوس یک دوازده‌وجهی


```

for (int i = 0; i < cameraPositions.Count; i++)
{
    using (Transaction t = new Transaction(doc, "Set Camera
Position"))
    {
        t.Start();

        // محاسبه و تنظیم جهتگیری دوربین در نمای سه‌بعدی
        XYZ eyePosition =
totalViewTransform.OfPoint(cameraPositions[i]);
        // ... (محاسبه وکتورهای دوربین) ...
        view.SetOrientation(new ViewOrientation3D(eyePosition,
finalUpVector, forwardVector));

        doc.Regenerate();
        t.Commit();
    }

    // خروجی گرفتن از نمای تنظیم‌شده به صورت فایل PNG
    string outputFileName = Path.Combine(outputFolder, $"{i +
1}.png");
    exportOptions.FilePath = outputFileName;
    doc.ExportImage(exportOptions);
}

```

قطعه کد ۳- حلقه اصلی رندرینگ برای تنظیم دوربین و خروجی گرفتن تصاویر ارتباط بین کلاینت و سرور به صورت ناهمگام^{۶۹} و با استفاده از AJAX برای ارسال درخواست اولیه و Socket.IO برای دریافت گزارش‌های زنده مدیریت می‌شود. قطعه کد زیر از فایل ApsRFACConversion.js، منطق اصلی سمت کلاینت برای آغاز فرآیند پیوسته را نمایش می‌دهد.

^{۶۹} Asynchronous

```
// ... تعریف رویداد کلیک برای دکمه ...
function startFullWorkflow() {
    // دریافت فایل‌ها از رابط کاربری ۱.
    const rfaZipFile = $('#fullWorkflowRfaZip')[0].files[0];
    const rvtTemplateFile =
    $('#fullWorkflowRvtTemplate')[0].files[0];

    if (!rfaZipFile || !rvtTemplateFile) {
        alert('را انتخاب نمایید RVT و Zip لطفاً هر دو فایل');
        return;
    }

    // آماده‌سازی داده‌ها برای ارسال به سرور ۲.
    const formData = new FormData();
    formData.append('rfaZipFile', rfaZipFile);
    formData.append('rvtTemplateFile', rvtTemplateFile);
    formData.append('data', JSON.stringify({
        browserConnectionId: connectionId, // شناسه ارتباط زنده
    }));

    // AJAX ارسال درخواست به سرور از طریق ۳.
    jQuery.ajax({
        url: '/api/aps/jobs/full-workflow', // در سرور API آدرس
        method: 'POST',
        data: formData,
        processData: false,
        contentType: false,
        success: function (res) {
            writeLog('فرآیند با موفقیت آغاز شد. در حال پایش وضعیت...');
        },
        error: function (xhr) {
            writeLog(`خطا در شروع فرآیند: ${xhr.responseText}`);
        },
    });
}
```

قطعه کد ۴- منطق اصلی سمت کلاینت جهت آغاز فرآیند پیوسته

همانطور که در کد مشخص است، پس از دریافت فایل‌ها، یک درخواست POST به آدرس `/api/aps/jobs/full-workflow` در سرور ارسال می‌شود. شناسه اتصال (`connectionId`) نیز برای سرور فرستاده می‌شود تا سرور بداند گزارش‌های زنده را به کدام کاربر ارسال کند.

قلب تپنده سیستم، سرور مبتنی بر Node.js است که وظیفه هماهنگی و اجرای زنجیره‌ای فرآیندها را بر عهده دارد. پس از دریافت درخواست از کلاینت، سرور مراحل زیر را به ترتیب اجرا می‌کند که در قطعه کد زیر از فایل `RFAConversion.js` خلاصه شده است:

۱. آماده‌سازی خودکار محیط APS: سرور ابتدا بررسی می‌کند که Appbundle ها و Activity های مورد نیاز برای هر دو مرحله (تبدیل و رندرینگ) بر روی سرویس APS^{۷۰} تعریف شده باشند و در صورت عدم وجود، آن‌ها را به صورت خودکار ایجاد می‌کند.
۲. اجرای مرحله اول (تبدیل فرمت): سرور یک WorkItem برای تبدیل فرمت RFA به RVT ایجاد کرده و وضعیت آن را تا رسیدن به نتیجه نهایی پایش می‌کند.
۳. اجرای مرحله دوم (رندرینگ): پس از اتمام موفقیت‌آمیز مرحله اول، سرور از خروجی آن (فایل RVT) به عنوان ورودی برای مرحله دوم استفاده کرده و یک WorkItem جدید برای رندرینگ تصاویر ایجاد و پایش می‌کند.
۴. ارسال نتیجه نهایی به کاربر: پس از اتمام موفقیت‌آمیز مرحله دوم، سرور لینک دانلود فایل نهایی (حاوی تصاویر) را از طریق کانال Socket.IO برای کاربر ارسال می‌کند.

```
// ... API endpoint برای تعریف ...
// -- مرحله ۱: اجرای فرآیند تبدیل فرمت --
socketIO.to(browserConnectionId).emit('onComplete', 'در حال اجرای ...');
let conversionWorkItem = await api.createWorkItem(conversionSpec);

// پایش وضعیت تا اتمام موفقیت‌آمیز
let conversionStatus = await pollWorkItem(conversionWorkItem.id, api, ...);
if (conversionStatus.status !== 'success') {
    throw new Error('فرآیند تبدیل فرمت با خطا مواجه شد');
}
const convertedRvtUrl = `...`; // خروجی RVT آدرس فایل

// -- مرحله ۲: اجرای فرآیند رندرینگ با خروجی مرحله قبل --
socketIO.to(browserConnectionId).emit('onComplete', 'تبدیل ...');
let renderWorkItem = await api.createWorkItem(renderSpec(convertedRvtUrl));

// پایش وضعیت تا اتمام موفقیت‌آمیز
let renderStatus = await pollWorkItem(renderWorkItem.id, api, ...);
if (renderStatus.status !== 'success') {
    throw new Error('فرآیند رندرینگ با خطا مواجه شد');
}

// -- مرحله ۳: ارائه لینک دانلود نهایی به کاربر --
const finalDownloadUrl = await objectsApi.getS3DownloadURL(...);
socketIO.to(browserConnectionId).emit('downloadResult', finalDownloadUrl.body.url);
```

قطعه کد ۵- خلاصه‌ای از منطق هماهنگ‌کننده در سرور Node.js

⁷⁰ Autodesk Platform Services

این رویکرد زنجیره‌ای و مدیریت خطا، اجرای یکپارچه، خودکار و قابل اعتماد کل عملیات را تضمین می‌کند.

۵-۵-۳ فرآیند فراخوانی و استنتاج نهایی

پس از آنکه فرآیند پیوسته در محیط APS، بیست نمای استاندارد دوبعدی را از شیء ورودی تولید کرد، این تصاویر به عنوان ورودی نهایی به بخش استنتاج^{۷۱} سیستم ارسال می‌شوند. این بخش که با یک اسکریپت^{۷۲} پایتون پیاده‌سازی شده است، مراحل زیر را به صورت خودکار انجام می‌دهد:

۱. بارگذاری مدل: مدل OVPT که قبلاً آموزش دیده و وزن‌های بهینه آن در یک فایل pth ذخیره شده است، در حافظه بارگذاری می‌شود.
 ۲. انتخاب نمای بهینه: اسکریپت، آنتروپی اطلاعات هر یک از بیست تصویر ورودی را محاسبه کرده و شش نمایی که دارای بیشترین محتوای اطلاعاتی هستند را انتخاب می‌کند.
 ۳. پیش‌بینی: شش نمای منتخب به مدل OVPT داده شده و مدل، یک بردار احتمال^{۷۳} برای تمام ۴۰ کلاس خروجی می‌دهد.
 ۴. ارائه نتیجه: در نهایت، پنج کلاس با بالاترین احتمال به همراه درصد اطمینان آن‌ها به عنوان نتیجه نهایی شناسایی و طبقه‌بندی به کاربر نمایش داده می‌شود.
- این مرحله نهایی، ارتباط بین خروجی فرآیند پیوسته مهندسی و ورودی مدل هوش مصنوعی را برقرار کرده و چرخه شناسایی و طبقه‌بندی را کامل می‌کند.

^{۷۱} Inference

^{۷۲} Script

^{۷۳} Probability Vector

۴ - فصل چهارم: پیاده‌سازی و نتایج

۴-۱ مقدمه

در این فصل نتایج حاصل از آموزش و ارزیابی مدل OVPT و همچنین عملکرد فرآیند پیوسته طراحی شده ارائه و تحلیل می‌شود. ابتدا عملکرد کلی مدل براساس معیارهای استاندارد ارزیابی شده و سپس تحلیلی دقیق بر روی عملکرد هر کلاس به صورت مجزا انجام می‌گیرد. در ادامه، ماتریس درهم‌ریختگی برای شناسایی خطاهای طبقه‌بندی بررسی شده و در نهایت یک مطالعه موردی از اجرای کامل فرآیند پیوسته از ابتدا تا انتها ارائه می‌گردد.

۴-۲ ارزیابی عملکرد کلی مدل

پس از اتمام فرآیند آموزش مدل OVPT بر روی دیتاست ModelNet40، عملکرد آن بر روی مجموعه داده آزمون که شامل ۲۰٪ از داده‌های دیده نشده می‌باشد، ارزیابی گردید. نتایج کلی عملکرد مدل در جدول زیر خلاصه شده‌است. این معیارها نشان‌دهنده توانایی مدل در تعمیم‌دهی به داده‌های جدید هستند.

جدول ۱ - گزارش ارزیابی عملکرد مدل آموزش دیده OVPT


مقدار	معیار
۹۷/۱۲٪	دقت کلی (Overall Accuracy – OA)
۹۶/۱۰٪	میانگین دقت کلاسی (Average Accuracy – AA)
۰/۹۷۰۹	دقت وزنی (Weighted Precision)
۰/۹۶۹۶	بازیابی وزنی (Weighted Recall)
۰/۹۶۹۷	امتیاز F1 وزنی (Weighted F1 Score)

دقت کلی ۹۷/۱۲٪ نشان می‌دهد که مدل توانسته است اکثریت قریب به اتفاق اشیاء سه‌بعدی را به درستی طبقه‌بندی کند. این نتیجه با نتایج گزارش شده در مقاله اصلی OVPT (که دقت ۹۷/۴۸٪ با ۶ نما را گزارش کرده‌است [۲]) بسیار نزدیک و قابل رقابت است که بیانگر پیاده‌سازی موفقیت آمیز مدل می‌باشد در صورتی

که به جای ۲۰ دوره^{۷۴} تنها ۱۰ دوره مدل آموزش داده شده است. میانگین دقتی کلاسی ۹۶/۱۰٪ نیز نشان می‌دهد که عملکرد مدل در بین کلاس‌های مختلف از توازن خوبی برخوردار است.

۳-۴ تحلیل عملکرد براساس هر کلاس

برای درک عمیق‌تر از نقاط قوت و ضعف مدل، عملکرد آن بر روی هر یک از ۴۰ کلاس دیتاست ModelNet40 به صورت جداگانه تحلیل شد. نمودار ستونی زیر معیارهای دقت، بازیابی و امتیاز F1 را برای هر کلاس نمایش می‌دهد.



شکل ۱۰- نمودار ستونی بررسی عملکرد مدل در هر کلاس

با تحلیل دقیق نتایج که در جدول بالا آمده است می‌توان کلاس‌ها را به چند دسته تقسیم کرد:

۱. کلاس‌های با عملکرد عالی: مدل در تشخیص برخی کلاس‌ها عملکردی نزدیک به ۱۰۰٪ داشته است. کلاس‌هایی مانند: پله، در، کیبورد، ماشین، انسان و هواپیما دارای امتیاز F1 برابر با ۱/۰ هستند که نشان‌دهنده تشخیص بدون خطا در مجموعه آزمون است. این کلاس‌ها معمولاً دارای ویژگی‌های بصری بسیار متمایز و تنوع درون کلاسی^{۷۵} کمتری هستند.

^{۷۴} Epoch

^{۷۵} Intra-class variation


۲. کلاس‌های با عملکرد خوب: بسیاری از کلاس‌ها مانند میز، صندلی، قفسه کتاب، تخت خواب، مبل با امتیاز F1 بالای ۰.۹۷ عملکرد بسیار خوبی از خود نشان داده‌اند.

۳. کلاس‌های چالش‌برانگیز: مدل در تشخیص تعداد محدودی از کلاس‌ها با چالش بیشتری روبه‌رو بوده‌است. برای مثال کلاس‌هایی مانند فنجان (امتیاز $F1: 0.8649$)، چهارپایه (امتیاز $F1: 0.8500$)، کمد لباس (امتیاز $F1: 0.8421$) و چادر (امتیاز $F1: 0.8372$) پایین‌ترین امتیازها را کسب کرده‌اند. دلایل احتمالی این عملکرد ضعیف‌تر می‌تواند شامل موارد زیر باشد:

- شباهت ظاهری بالا با کلاس‌های دیگر: برای مثال چهارپایه ممکن است با صندلی و یا نیمکت اشتباه گرفته شود.
 - تنوع زیاد درون یک کلاس: اشیائی مانند گلدان یا چراغ می‌توانند شکل‌های بسیار متنوعی داشته باشند که کار را برای یادگیری یک الگوی واحد توسط مدل را دشوار می‌کند.
 - تعداد نمونه‌های کمتر در دیتاست: برخی کلاس‌ها ممکن است نمونه‌های کمتری در مجموعه داده داشته باشند که منجر به یادگیری ضعیف‌تر ویژگی‌ها می‌شود.
- همچنین نتایج تست‌های انجام شده در جدول ۲ در پیوست ضمیمه شده است.

۴-۴ تحلیل ماتریس درهم‌ریختگی^{۷۶}

ماتریس درهم‌ریختگی ابزاری بصری برای تحلیل دقیق خطاهای طبقه‌بندی است. این ماتریس نشان می‌دهد که مدل کدام کلاس‌ها را با یکدیگر اشتباه گرفته‌است. در ماتریس زیر، محور عمودی عنوان واقعی و محور افقی عنوان پیش‌بینی شده را نشان می‌دهد. در حالت ایده‌آل تمام مقادیر باید روی قطر اصلی ماتریس متمرکز باشند.



شکل ۱۱- ماتریس درهم‌ریختگی

تحلیل این ماتریس نتایج بخش قبل را تأیید می‌کند:

- قطر اصلی پررنگ: همانطور که مشاهده می‌شود، قطر اصلی ماتریس بسیار پررنگ است که نشان‌دهنده نرخ بالای طبقه‌بندی صحیح در اکثر کلاس‌ها است. کلاس‌هایی مانند تخت، صندلی، در و... به طور کامل (۱۰۰٪) به درستی تشخیص داده شده‌اند.
- نقاط سردرگمی^{۷۷}: با بررسی نقاط خارج از قطر اصلی، می‌توان به خطاهای خاص مدل پی‌برد. برای مثال، همانطور که در مقاله اصلی OVPT نیز اشاره شده است، اشیائی که ویژگی‌های بصری مشابهی دارند، بیشتر دچار خطا می‌شوند. در نتایج این پژوهش نیز مشاهده می‌شود که کلاس‌هایی مانند میز کنار تخت با کمد، گلدون با لامپ اندکی اشتباه گرفته شده‌اند. این خطاها

⁷⁷ Confusion Points

منطقی به نظر می‌رسند زیرا این جفت اشیاء اغلب از زوایای خاص شباهت زیادی به یکدیگر دارند.


به‌طور کلی ماتریس درهم‌ریختگی نشان می‌دهد که مدل OVPT در تفکیک کلاس‌ها بسیار موفق عمل کرده و خطاهای آن محدود و قابل تفسیر هستند.

۴-۵ نتایج آزمون عملی فرآیند پیوسته

برای ارزیابی عملکرد این سیستم در یک سناریوی واقعی، یک مطالعه موردی بر روی یک فایل نمونه اجرا شد. هدف این آزمون، نمایش کارکرد صحیح و یکپارچه کل فرآیند از دریافت فایل RFA تا ارائه نتیجه نهایی بود.

- مرحله ۱- ورودی:


یک فایل zip حاوی مدل سه‌بعدی یک صندلی در فرمت RFA به همراه یک فایل تمپلیت rvt. از طریق رابط کاربری تحت وب که در تصویر زیر نمایش داده شده بارگذاری می‌شود.



شکل ۱۲- بارگذاری فایل‌های RFA و تمپلیت RVT در رابط کاربری تحت‌وب

- مرحله ۲- اجرا:

با یک کلیک بر روی دکمه “Start Full Workflow”، فرآیند خودکار در پلتفرم APS آغاز می‌شود.




شکل ۱۳- کلیک کردن بر روی دکمه ی شروع فرآیند خودکار و آغاز به کار کردن پلتفرم APS

• مرحله ۳- پردازش در Backend:

❖ تبدیل فرمت: ابتدا، فعالیت اول در APS اجرا شده و فایل RFA با موفقیت به فرمت RVT


تبدیل شد.



شکل ۱۴- پیام موفقیت آمیز بودن مرحله تبدیل فرمت RFA به RVT و شروع انجام مرحله رندرینگ بلافاصله بعد از آن


❖ رندرینگ: سپس فایل RVT خروجی به عنوان ورودی به فعالیت دوم داده شد و ۲۰ نما از

مدل صندلی براساس الگوی دوازده وجهی تولید و در قالب فایل png ذخیره گردید.



شکل ۱۵- پیام موفقیت‌آمیز بودن مرحله رندرینگ و خروجی قابل داندلود تصاویر

در شکل ۱۶ خروجی گرفته شده را مشاهده می‌کنید که مدل هوش مصنوعی این تصاویر را بررسی می‌کند و نتایج خود را گزارش می‌کند




شکل ۱۶- خروجی گرفته شده از فرآیند پیوسته ایجاد شده جهت تشخیص شیء توسط هوش مصنوعی OVPT

- مرحله ۴- فراخوانی و استنتاج:

- ❖ تصاویر تولید شده به اسکریپت^{۷۸} "inference4.py" ارسال شدند.
- ❖ توسط اسکریپت ابتدا آنتروپی هر ۲۰ تصویر را محاسبه کرده و ۶ تصویر با بیشترین محتوای اطلاعاتی را به عنوان **مجموعه نمای بهینه** انتخاب شد.
- ❖ این ۶ تصویر به مدل OVPT آموزش دیده داده شدند.

• مرحله ۵- خروجی نهایی:

کلاس شیء را با موفقیت پیش‌بینی کرد و ۵ پیش‌بینی برتر به همراه درصد اطمینان آن‌ها به صورت زیر نمایش داده شد:



شکل ۱۷- خروجی نهایی: انتخاب بهترین نماها با استفاده از آنتروپی اطلاعات آن‌ها، استفاده تنها ۶ نمای انتخاب شده از ۲۰ نمای خروجی فرآیند پیوسته طراحی شده و در نهایت پیش‌بینی درست شیء توسط مدل

این آزمون عملی نشان می‌دهد که فرآیند پیوسته طراحی شده به صورت کاملاً خودکار عمل کرده و قادر است یک شیء BIM را از فرمت خام اولیه دریافت، پردازش و طبقه‌بندی نماید.

۵ - فصل پنجم: بحث و نتیجه گیری

۵-۱ تحلیل و تفسیر نتایج

نتایج ارائه شده در فصل چهارم، موفقیت آمیز بودن رویکرد اتخاذ شده در این پژوهش را به وضوح نشان می دهد. دستیابی به دقت کلی ۹۷.۱۲٪ بر روی دیتاست چالش برانگیز ModelNet40، بیانگر آن است که مدل OVPT یک مدل بسیار قدرتمند برای شناسایی و طبقه بندی اشیاء سه بعدی است. موفقیت این مدل را می توان به چند عامل کلیدی نسبت داد:

- ساز و کار انتخاب نمای بهینه: همانطور که در مقاله اصلی (Wang و همکاران [۲]) و مقاله مروری (Alzahrani و همکاران [۱]) نیز تأکید شده، قابلیت مدل در انتخاب هوشمند نماهای حاوی بیشترین اطلاعات بر اساس آنروپی، نه تنها هزینه محاسباتی را کاهش می دهد، بلکه با حذف نماهای افزونه یا گمراه کننده، به افزایش دقت نهایی نیز کمک می کند.
- قدرت معماری ترنسفورمر: برخلاف مدل های مبتنی بر CNN که ویژگی های هر نما را به صورت مجزا پردازش کرده و در لایه نهایی تجمیع می کنند، معماری ترنسفورمر در OVPT قادر است روابط متقابل و پیچیده بین تمامی نماها را به صورت همزمان مدل سازی کند. این قابلیت به مدل اجازه می دهد تا یک درک جامع و سراسری از هندسه شیء به دست آورد که برای تفکیک کلاس های با شباهت ظاهری بالا، حیاتی است.
- یکپارچگی فرآیند پیوسته صنعتی: موفقیت آزمون عملی، اهمیت طراحی یک فرآیند پیوسته پایدار و یکپارچه را نشان می دهد. استفاده از APS تضمین کرد که فرآیند آماده سازی داده (تبدیل فرمت و رندرینگ) به صورت استاندارد، قابل تکرار و با کیفیت بالا انجام شود. این پایداری در ورودی، مستقیماً به عملکرد بهتر و قابل اعتمادتر مدل هوش مصنوعی منجر می شود. مقایسه نتایج این پژوهش با کارهای پیشین (مانند Koo et al., 2021a)، برتری مدل های مبتنی بر ترنسفورمر نسبت به مدل های کلاسیک CNN را در این حوزه تأیید می کند.

۵-۲ محدودیت های تحقیق

با وجود نتایج موفقیت آمیز، این پژوهش با محدودیت های عملی و فنی نیز مواجه بود که بر فرآیند تحقیق تأثیر گذار بودند:

- چالش‌های دسترسی به زیرساخت‌ها: تحریم‌های بین‌المللی، دسترسی مستقیم و پایدار به پلتفرم‌های ابری مانند Autodesk Design Automation را با دشواری‌هایی مواجه ساخت که نیازمند استفاده از راهکارهای جایگزین بود.
- محدودیت‌های نرم‌افزاری: عدم دسترسی به نسخه‌های اصلی و به‌روز نرم‌افزارهایی مانند Autodesk Revit، توسعه و آزمون افزونه‌ها را با چالش‌هایی همراه کرد. این موضوع همچنین دسترسی به آخرین نسخه‌های کتابخانه‌های پیوند پویا (DLLها) را محدود کرده و مانع از بهره‌گیری از جدیدترین قابلیت‌های افزوده شده به موتور نرم‌افزار جهت خروجی گرفتن هرچه بهتر نماها می‌شد.
- محدودیت دیتاست: اگرچه ModelNet40 یک معیار استاندارد عالی برای محک‌زنی است، اما لزوماً نماینده تنوع کامل اشیاء موجود در کتابخانه‌های BIM نیست. تعمیم مستقیم نتایج به تمام انواع اشیاء BIM باید با احتیاط انجام شود.

۳-۵ پیشنهادات برای کارهای آینده

- استفاده از دیتاست‌های تخصصی BIM: مدل آموزش‌دیده و فرآیند پیوسته توسعه‌یافته می‌تواند در گام بعدی بر روی دیتاست‌های تخصصی مانند ArchShapesNet آموزش‌دیده و ارزیابی شود تا عملکرد آن به طور خاص در حوزه معماری سنجیده شود.
- تولید داده‌های مصنوعی^{۷۹}: با استفاده از رویکرد افزایش پارامتریک داده می‌توان دیتاست‌های بزرگ و متعادلی از اشیاء BIM تولید کرد تا دقت و قابلیت تعمیم‌پذیری مدل بیش از پیش افزایش یابد.
- افزایش مقیاس‌پذیری با یادگیری بدون نظارت و تقویتی: برای مدیریت حجم عظیم اشیاء در کتابخانه‌های ملی، می‌توان از روش‌های یادگیری بدون نظارت برای خوشه‌بندی اولیه اشیاء و یا از یادگیری تقویتی برای بهینه‌سازی فرآیند انتخاب نما بهره برد.
- یکپارچه‌سازی با عامل‌های هوشمند (AI Agents): می‌توان سیستم فعلی را به یک عامل هوشمند مجهز کرد که قادر باشد به صورت خودکار فرآیند نظارت، طبقه‌بندی، گزارش‌دهی و حتی اصلاح خطاهای احتمالی را در یک گردش کار کاملاً مستقل و بدون نیاز به نظارت انسانی مدیریت کند.

۵-۴ نتیجه‌گیری نهایی

این پژوهش با موفقیت یک سیستم هوشمند، یکپارچه و صنعتی برای طبقه‌بندی خودکار اشیاء سه‌بعدی BIM طراحی و پیاده‌سازی کرد. با ترکیب قدرت مدل پیشرفته OVPT مبتنی بر معماری ترنسفورمر و پایداری پلتفرم ابری Autodesk Platform Services، این تحقیق توانست به دو شکاف اصلی در پژوهش‌های پیشین، یعنی محدودیت‌های مدل‌سازی و شکنندگی پیاده‌سازی، به طور همزمان پاسخ دهد.

نتایج نشان داد که سیستم ارائه‌شده قادر است با دقت و کارایی بسیار بالا، فرآیند زمان‌بر و پرخطای طبقه‌بندی دستی را خودکار سازد. این دستاورد، گامی مهم در جهت افزایش بهره‌وری، استانداردسازی و قابلیت اطمینان در مدیریت کتابخانه‌های اشیاء BIM و تقویت اکوسیستم مدل‌سازی اطلاعات ساخت در صنعت AEC^{۸۰} محسوب می‌شود.

⁸⁰ Architecture, Engineering, and Construction

مراجع

- [۱] M. Alzahrani, M. Usman, S. K. Jarraya, S. Anwar, and T. Helmy, "Deep models for multi-view 3d object recognition: A review," *Artificial Intelligence Review*, vol. 57, no. 12, pp. 1-71, 2024.
- [۲] W. Wang, G. Chen, H. Zhou, and X. Wang, "Ovpt: Optimal viewset pooling transformer for 3d object recognition," in *Proceedings of the asian conference on computer vision*, 2022, pp. 4444-4461 .
- [۳] V. Bazjanac and A. Kiviniemi, "Reduction, simplification, translation and interpretation in the exchange of model data," 2007 .
- [۴] T. Pazlar and Ž. Turk, "Interoperability in practice: Geometric data exchange using the IFC standard," *Electronic Journal of Information Technology in Construction*, vol. 13, pp. 362-380, 06/01 2008.
- [۵] M. Belsky, R. Sacks, and I. Brilakis, "Semantic Enrichment for Building Information Modeling," *Computer-Aided Civil and Infrastructure Engineering*, vol. 31, no. 4, pp. 261-274, 2016, doi: <https://doi.org/10.1111/mice.12128>.
- [۶] L. Ma, R. Sacks, and U. Kattel, *Building Model Object Classification for Semantic Enrichment Using Geometric Features and Pairwise Spatial Relationships*. 2017, pp. 373-380.
- [۷] J. B. Michael M. Bronstein, Yann LeCun, Arthur Szlam, Pierre Vandergheynst, "Geometric deep learning: going beyond Euclidean data," *IEEE Signal Processing Magazine*, vol. 34, pp. 18–42, 2017, doi: 10.1109/msp.2017.2693418.
- [۸] W. Zhirong *et al.*, "3D ShapeNets: A deep representation for volumetric shapes," in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 7-12 June 2015, pp. 1912-1920, doi: 10.1109/CVPR.2015.7298801 .
- [۹] R. Q. Charles, H. Su, M. Kaichun, and L. J. Guibas, "PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 21-26 July 2017 2017, pp. 77-85, doi: 10.1109/CVPR.2017.16 .
- [۱۰] H. Su, S. Maji, E. Kalogerakis, and E. Learned-Miller, "Multi-view Convolutional Neural Networks for 3D Shape Recognition," in *2015 IEEE International Conference on Computer Vision (ICCV)*, 7-13 December 2015 2015, pp. 945-953, doi: 10.1109/ICCV.2015.114. [Online]. Available: <http://doi.ieeecomputersociety.org/10.1109/ICCV.2015.114>
- [۱۱] B. Koo, R. Jung, Y. Yu, and I. Kim, "A geometric deep learning approach for checking element-to-entity mappings in infrastructure building information models," *Journal of Computational Design and Engineering*, vol. 8, no. 1, pp. 239-250, 2020, doi: 10.1093/jcde/qwaa075.
- [۱۲] S. Qi *et al.*, "Review of Multi-view 3D Object Recognition Methods Based on Deep Learning," *Displays*, vol. 69, p. 102053, 07/01 2021, doi: 10.1016/j.displa.2021.102053.
- [۱۳] Y. Yu, D. Ha, K. Lee, J. Choi, and B. Koo, "ArchShapesNet: a novel dataset for benchmarking architectural building information modeling element classification algorithms," *Journal of Computational Design and Engineering*, vol. 9, no. 4, pp. 1449-1466, 2022, doi: 10.1093/jcde/qwac064.

پیوست

جدول ۲ - نتایج عملکرد مدل OVPT آموزش دیده، بر هر کلاس

Class	Precision	Recall	F1	Support
airplane	1.0000	1.0000	1.0000	100
bathtub	1.0000	0.9200	0.9583	50
bed	0.9804	1.0000	0.9901	100
bench	1.0000	0.9000	0.9474	20
bookshelf	0.9706	0.9900	0.9802	100
bottle	0.9703	0.9800	0.9751	100
bowl	0.8636	0.9500	0.9048	20
car	1.0000	1.0000	1.0000	100
chair	0.9901	1.0000	0.9950	100
cone	1.0000	1.0000	1.0000	20
cup	0.9412	0.8000	0.8649	20
curtain	0.9000	0.9000	0.9000	20
desk	0.9659	0.9884	0.9770	86
door	1.0000	1.0000	1.0000	20
dresser	0.9885	1.0000	0.9942	86
flower_pot	0.7692	1.0000	0.8696	20
glass_box	1.0000	0.9600	0.9796	100
guitar	1.0000	1.0000	1.0000	100
keyboard	1.0000	1.0000	1.0000	20
lamp	0.9000	0.9000	0.9000	20
laptop	0.9524	1.0000	0.9756	20
mantel	0.9900	0.9900	0.9900	100
monitor	1.0000	0.9700	0.9848	100
night_stand	0.9620	0.8837	0.9212	86
person	1.0000	1.0000	1.0000	20
piano	0.9800	0.9800	0.9800	100
plant	0.9900	0.9900	0.9900	100
radio	0.8696	1.0000	0.9302	20
range_hood	0.9896	0.9500	0.9694	100
sink	0.9444	0.8500	0.8947	20

sofa	1.0000	0.9900	0.9950	100
stairs	1.0000	1.0000	1.0000	20
stool	0.8500	0.8500	0.8500	20
table	0.9083	0.9900	0.9474	100
tent	0.7826	0.9000	0.8372	20
toilet	0.9900	0.9900	0.9900	100
tv_stand	0.9208	0.9300	0.9254	100
vase	0.9684	0.9200	0.9436	100
wardbore	0.8889	0.8000	0.8421	20
xbox	0.8696	1.0000	0.9302	20